Visión por Computadora II
CEAI - FIUBA

Docente:

- Gerardo Vilcamiza Espinoza - gvilcamiza.ext@fi.uba.ar

Programa de la materia

1. **Clase 1:** Introducción a las tareas de visión por computadora potenciadas por Deep Learning. Componentes y arquitectura fundamental de una Red Neuronal Convolucional (CNN).
2. **Clase 2:** EDA y técnicas de pre-procesamiento de imágenes. Data Augmentation. Capas de regularización y normalización en una CNN. Explicación del trabajo práctico.
3. **Clase 3**: Modelos pre-entrenados para clasificación de imágenes. Transfer Learning.
4. **Clase 4:** Modelos de detección de objetos y tracking.
5. **Clase 5:** Modelos de segmentación por instancias y segmentación semántica.
6. **Clase 6:** Fundamentos de IA generativa aplicada a imágenes. Neural Style Transfer. Autoencoders.
7. **Clase 7:** Red Generativa Adversaria Convolucional Profunda (DC-GAN). SRGANs. Image Colorizer Models.
8. **Clase 8:** Nuevas tendencias de la visión por computadora. Presentación de trabajos prácticos.

Clasificación (Image Classification)

Este tipo de problemas se trata de asociar una imagen dada, a una o varias clases de un conjunto predefinido de las mismas. La salida del modelo será entonces, la clase predicha y el score de confianza correspondiente a esa clase.

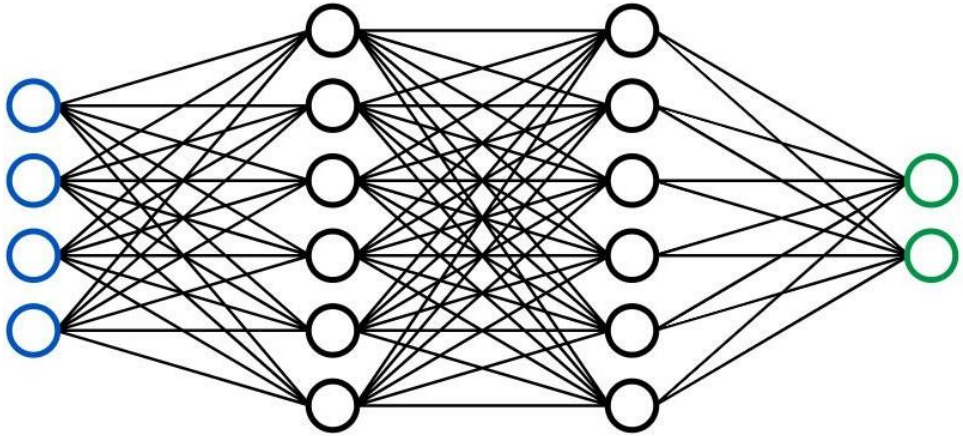

Pájaro (83%)

Pez (17%)

Datasets clásicos: MNIST, Fashion-MNIST, CIFAR-10, ImageNet, etc.

Detección de objetos (Object detection)

El objetivo es encontrar la posición en la que se encuentra un objeto de interés, pudiendo haber más de uno de ellos a la vez en la misma imagen. La salida son las coordenadas de los “bounding boxes” o recuadros asociados a cada objeto y clase encontrada en la imagen, así como el score de confianza de la detección.

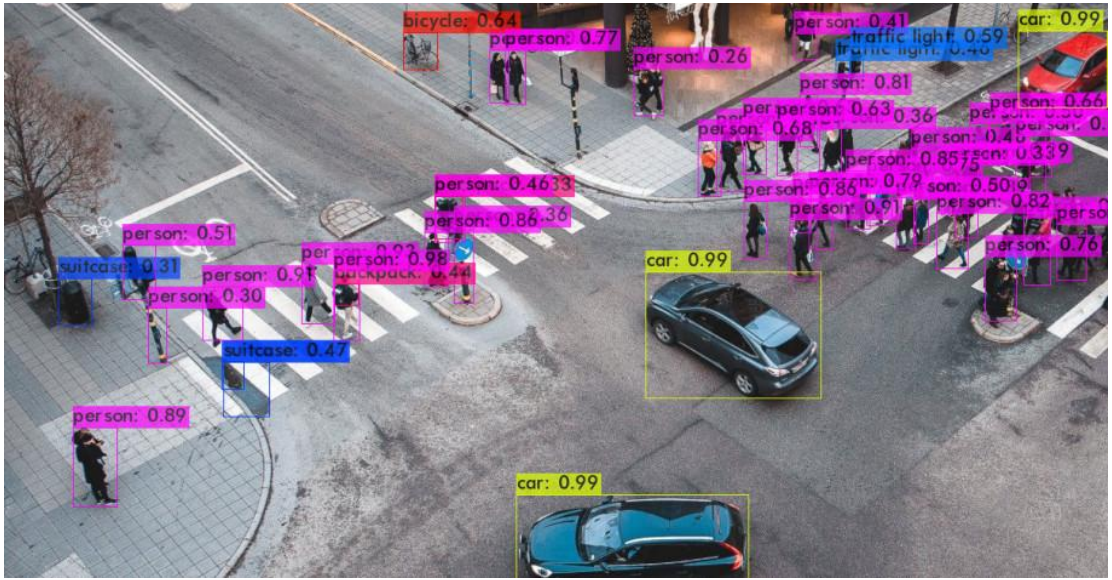

Datasets: COCO, Pascal VOC, Imagenet, Open Images, etc

Segmentación de Instancias (Instance Segmentation)

Muy similar a la detección de objetos, estos modelos tienen la tarea de localizar objetos y reconocer su clase, pero ahora ya no solo se señala con un “bounding box”, sino que se marca la silueta del objeto. Dando como salida toda la máscara de píxeles que corresponden al objeto y el score de confianza del reconocimiento de la clase.

Datasets: COCO, Pascal VOC, Open Images, Cityscapes, etc

Segmentación Semántica (Semantic Segmentation)

La segmentación semántica consiste en asignarle una clase a cada uno de los pixeles de una imagen. Esto es útil para poder separar diversas zonas de la misma (grupos de pixeles) en regiones de interés que comparten las mismas características, es decir, pertenecen a la misma clase, sin diferenciar entre objetos de la misma clase.

Datasets: COCO, Pascal VOC, Open Images, Cityscapes, etc

Otras tendencias

El Deep Learning aplicado a las imágenes ha permitido desarrollar algoritmos que generan imágenes realistas, hacen transferencia de estilo o traducen texto a imágenes, entre otras.

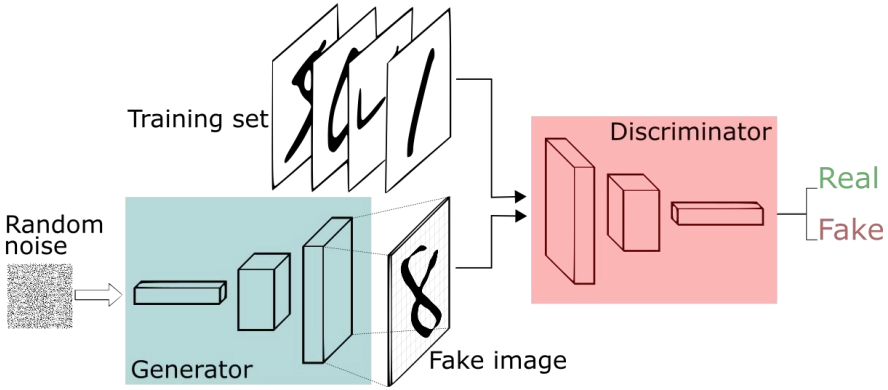

Super-resolución

Real ESRGAN: Es capaz de aumentar la resolución de imágenes sin afectar la calidad de los detalles. Incluso se puede utilizar como una forma de restaurar imágenes. https://github.com/xinntao/Real-ESRGAN

Colorización

DeOldify: Realiza el proceso de coloreo de imágenes antiguas o en blanco y negro.
https://github.com/jantic/DeOldify

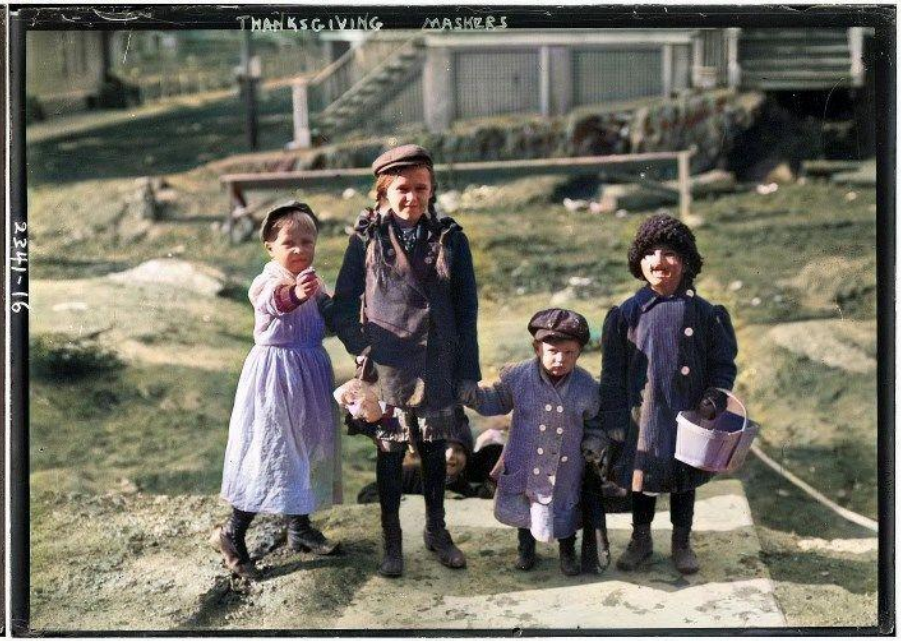

Generación de imágenes por prompt

DALL.E 2: Puede crear imágenes realistas a partir de una descripción en lenguaje natural.

En el ejemplo de la imagen la descripción fue:

"a living room with two white armchairs and a painting of the collosseum. the painting is mounted above a modern fireplace"

https://openai.com/dall-e-2/

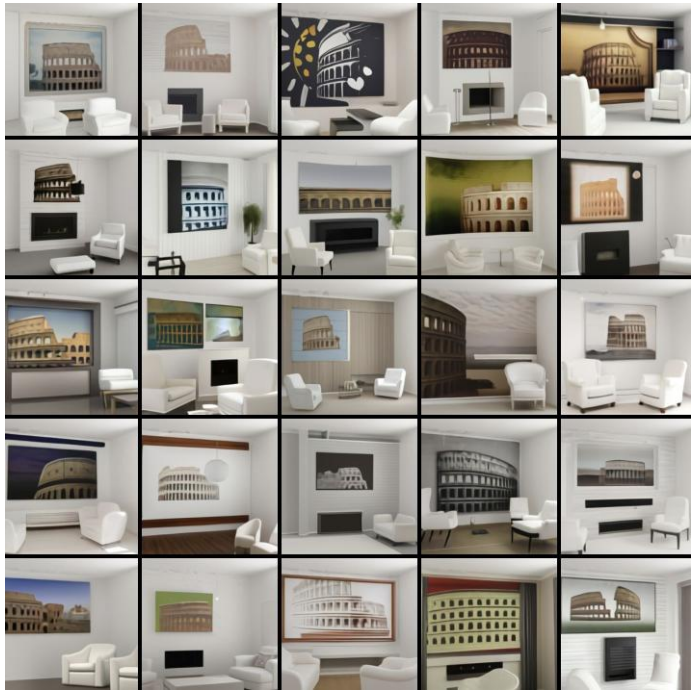

Modelos de difusión

Stable Diffusion es similar a DALL.E 2 pero desarrollada por un grupo independiente y es de código abierto!

En el ejemplo de la imagen la descripción fue:

"a photograph of an astronaut riding a horse"

https://stability.ai/blog/stable-diffusion-public-release

https://github.com/CompVis/stable-diffusion

https://colab.research.google.com/github/huggingface/notebooks/blob/main/diffusers/stable_diffusion.ipynb

Segmentación no supervisada

SAM (Segment Anything Model) es un modelo de segmentación capaz de generalizar sobre objetos y clases sobre las que no fue entrenado. Fue desarrollado por Meta. Se considera un modelo semi-supervisado.

Website: https://segment-anything.com/ y blog: link

Generación de video

Sora es un modelo desarrollado por OpenAI que puede transformar descripciones de texto en videos super realistas.

Prompt:
A movie trailer featuring the adventures of the 30-year-old space man wearing a red wool knitted motorcycle helmet, blue sky, salt desert, cinematic style, shot on 35 mm film, vivid colors.

Website: https://openai.com/index/sora/ y blog: link

Modelos de estimación de profundidad

Los modelos de estimación de profundidad son técnicas de visión por computadora que permiten inferir la distancia relativa de los objetos en una escena a partir de imágenes, generando un mapa de profundidad donde cada píxel representa qué tan cerca o lejos está respecto a la cámara. A diferencia de sensores físicos como LiDAR, estos modelos pueden trabajar únicamente con información visual 2D capturada de una cámara común.

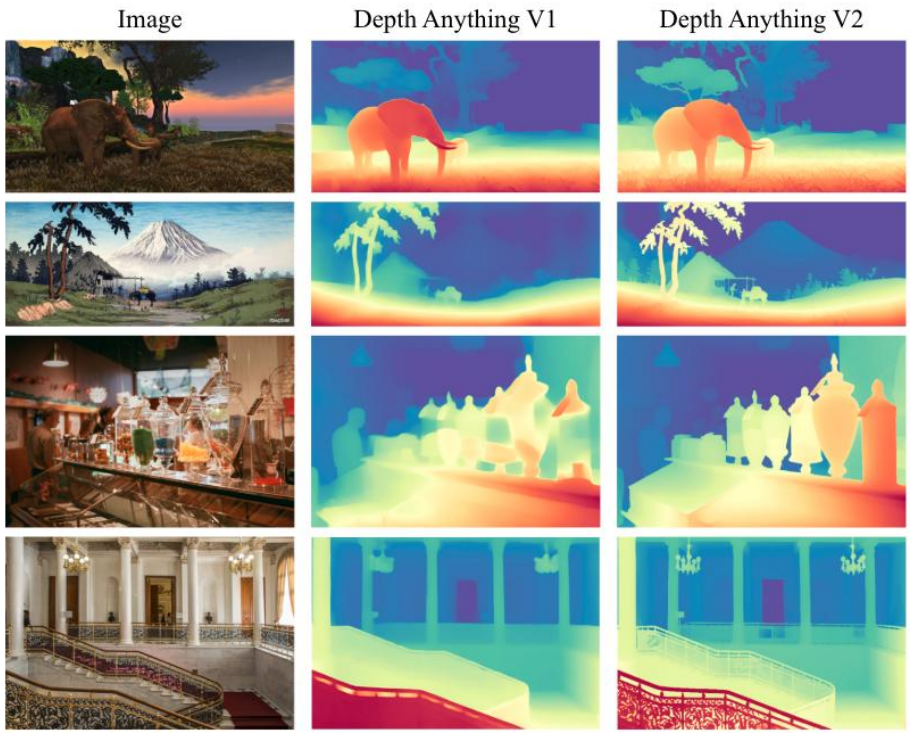

Modelos descriptores de imagen

Los modelos de image captioning son sistemas de inteligencia artificial que generan descripciones en lenguaje natural a partir de imágenes. Su objetivo es traducir la información visual en texto coherente, capturando tanto los objetos presentes como las relaciones y el contexto de la escena. A diferencia de los grandes modelos de lenguaje (LLMs), estos modelos están diseñados específicamente para tareas multimodales enfocadas en la comprensión visual, no para mantener conversaciones generales.

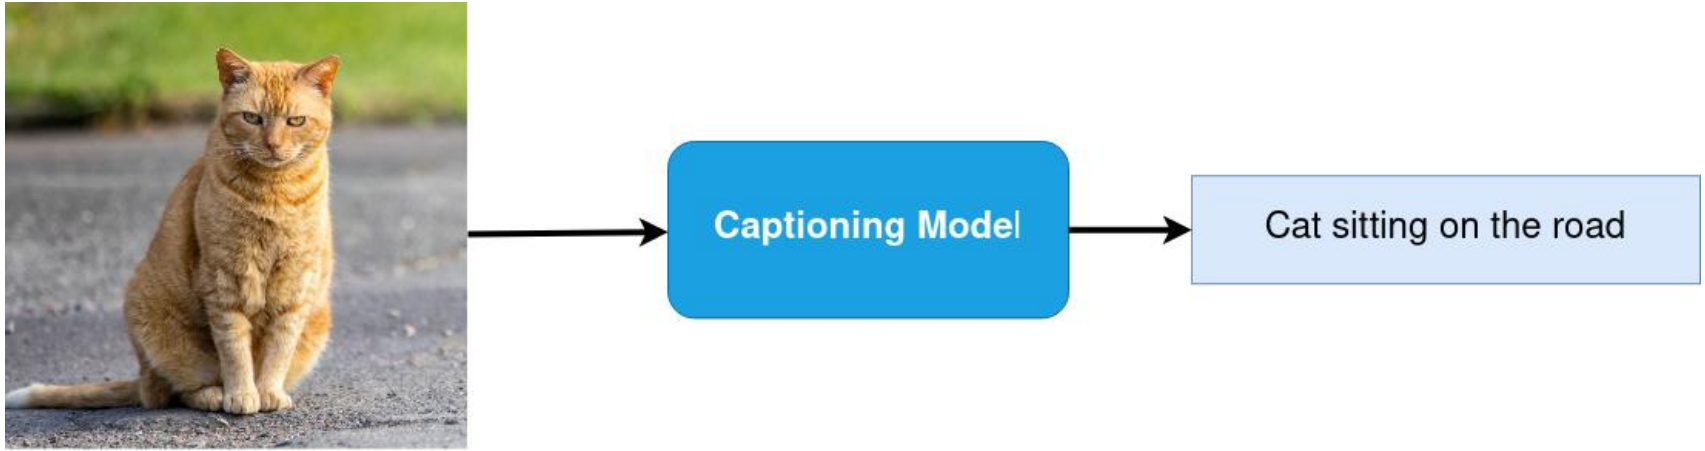

Algunos desafíos:

Invariancia a la traslación

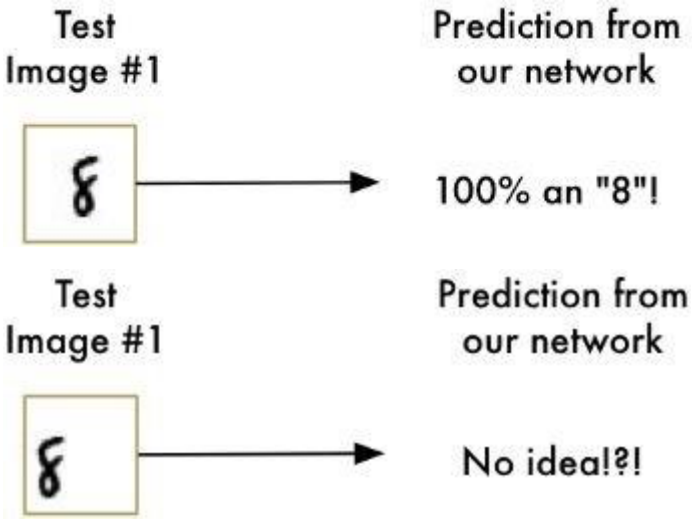

Características localizadas

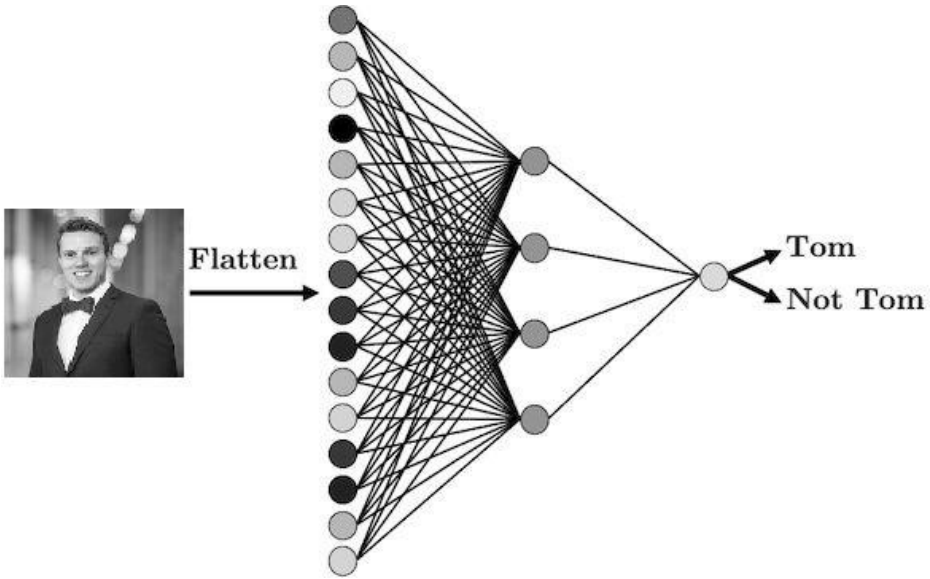

Algunos desafíos:

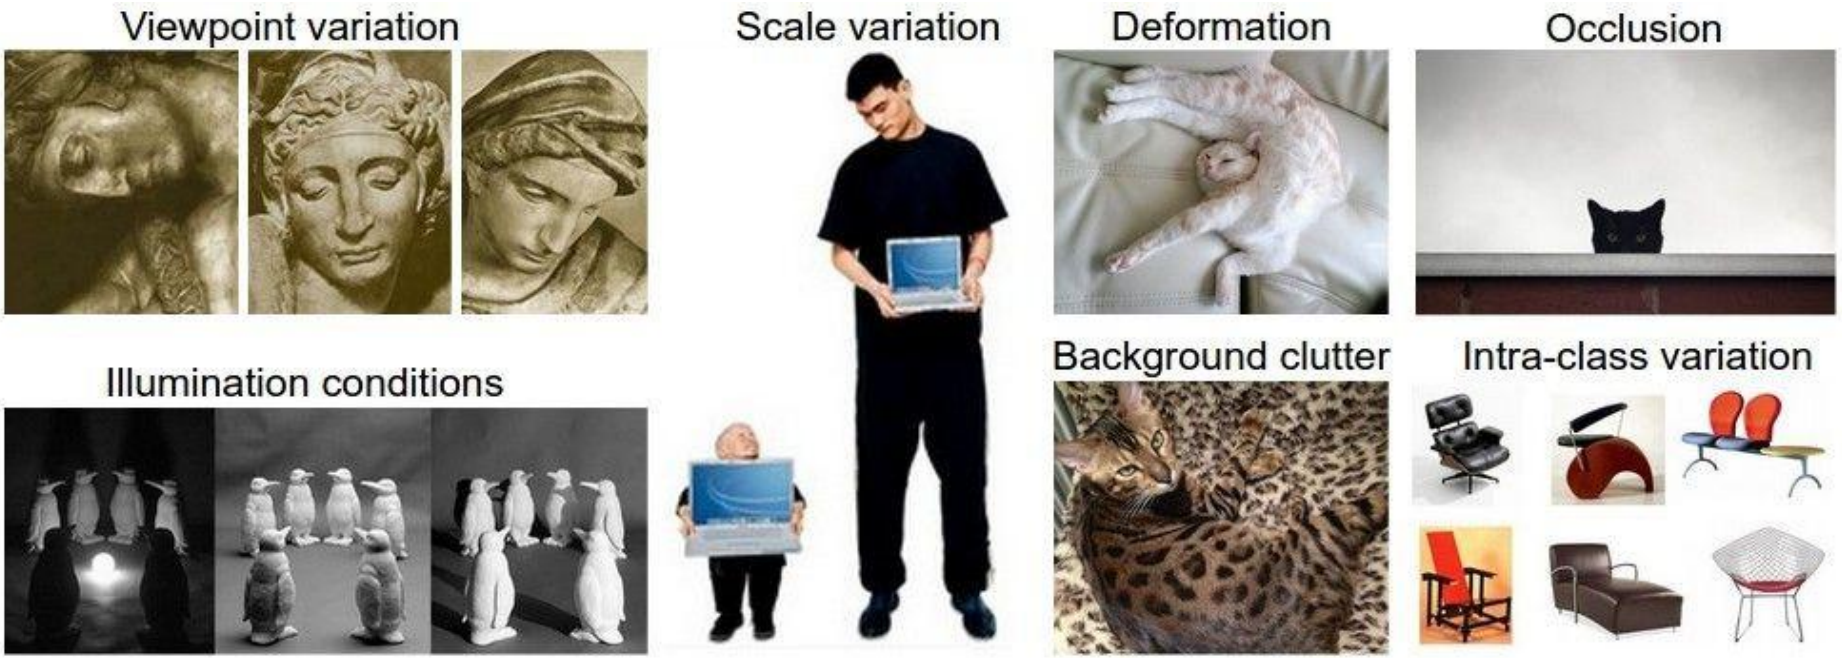

Algunos desafíos:

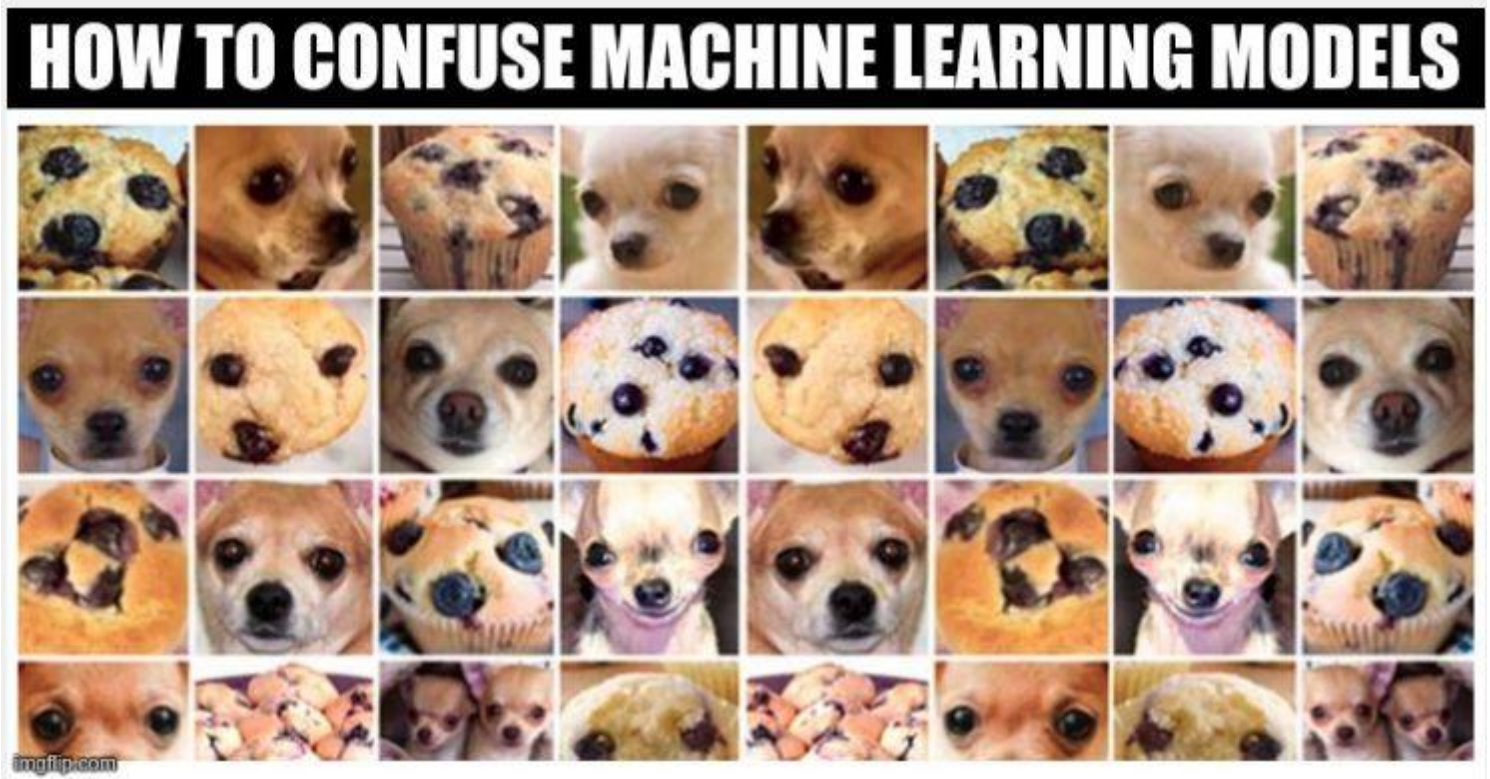

Redes Neuronales Convolucionales (CNNs)

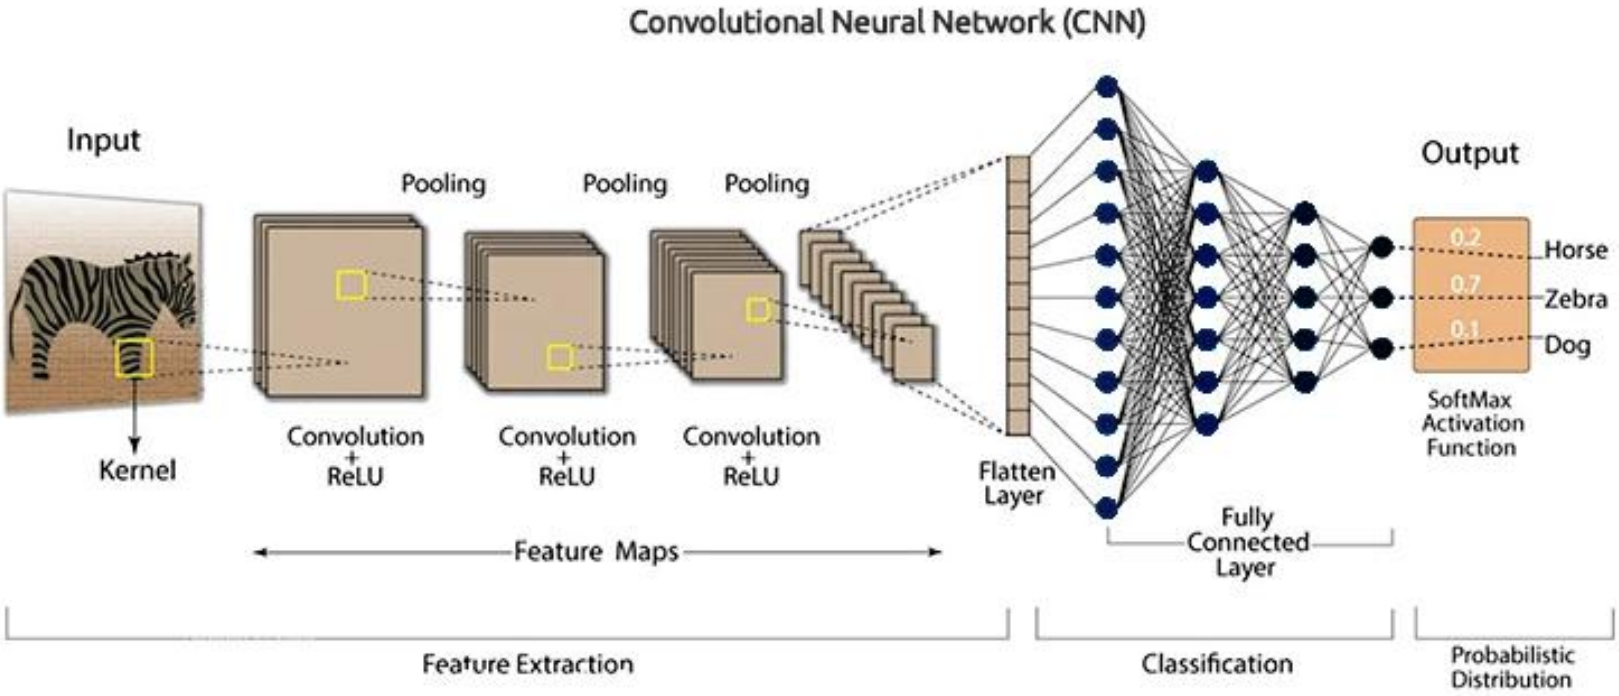

Convolución

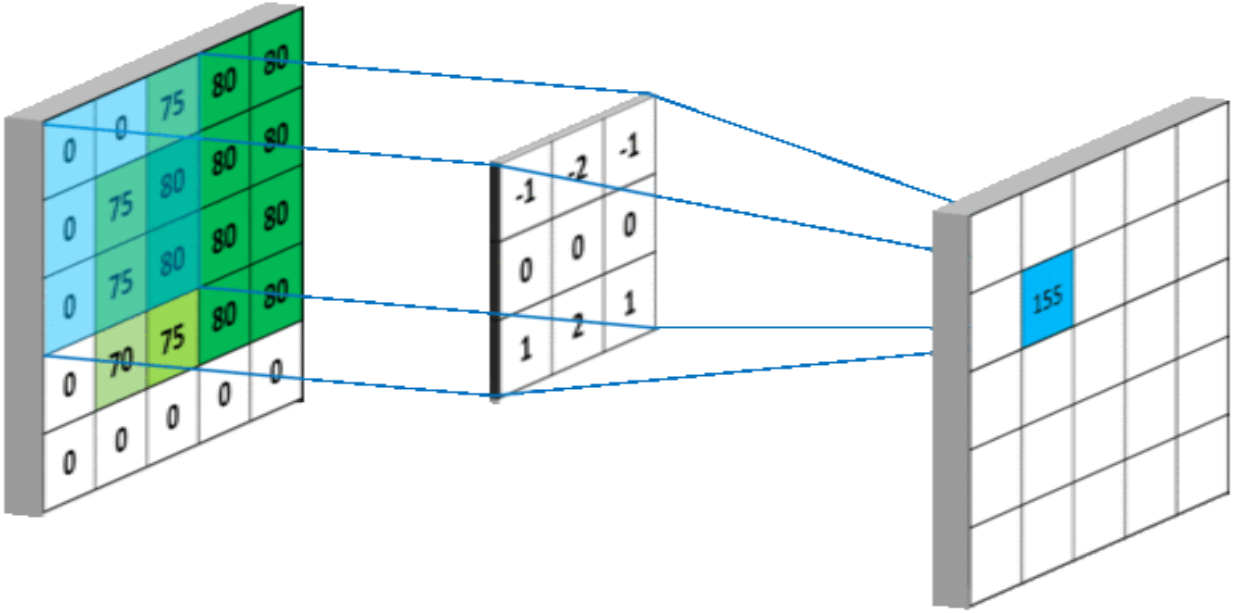

Convolución

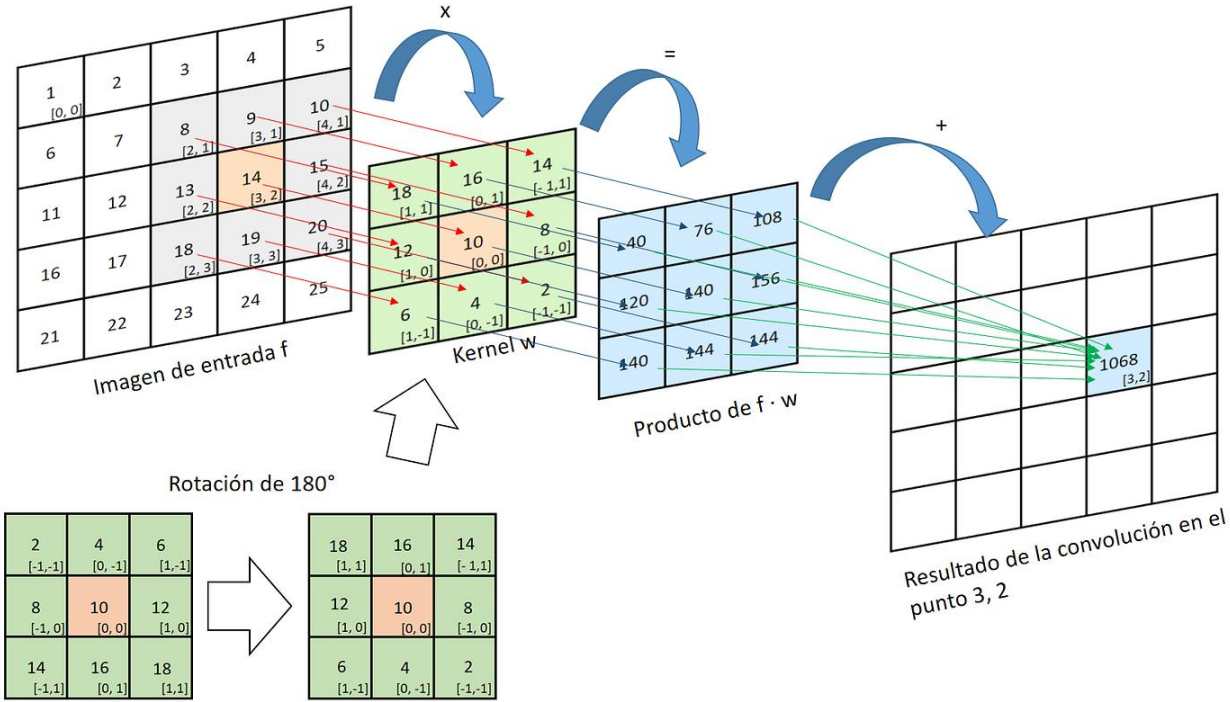

Convolución – Kernel de media

1/9	1/9	1/9
1/9	1/9	1/9
1/9	1/9	1/9

Imagen Original

Filtro de Media 3x3

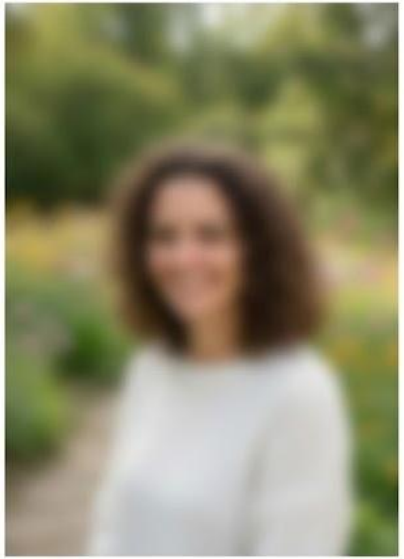

Convolución – Kernel gaussiano

1	4	7	4	1
4	16	26	16	4
7	26	41	26	7
4	16	26	16	4
1	4	7	4	1

Original image

Gaussian Blur filter applied

Convolución – Kernel gaussiano

-1	0	+1
-2	0	+2
-1	0	+1

Gx

+1	+2	+1
0	0	0
-1	-2	-1

Gy

0	-1	0
-1	4	-1
0	-1	0

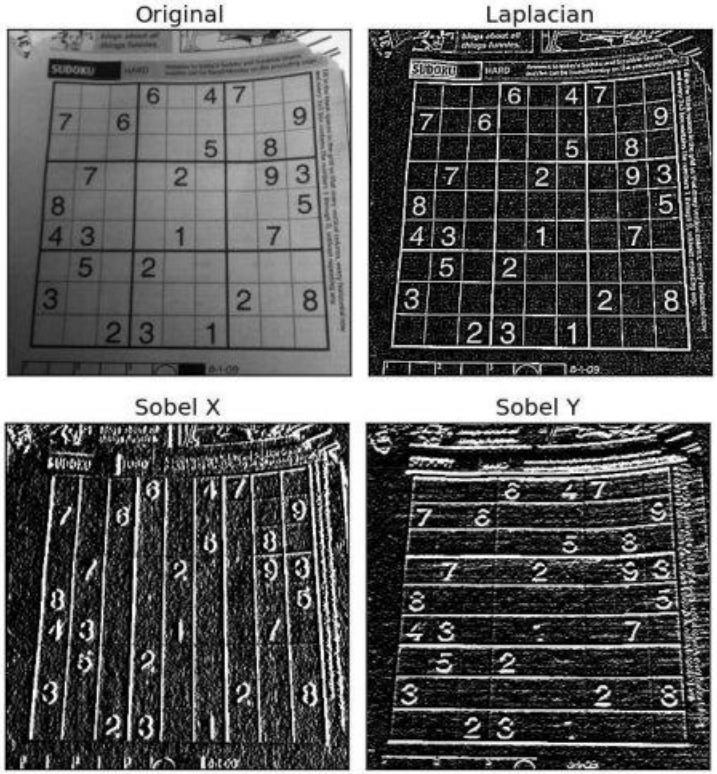

Pooling

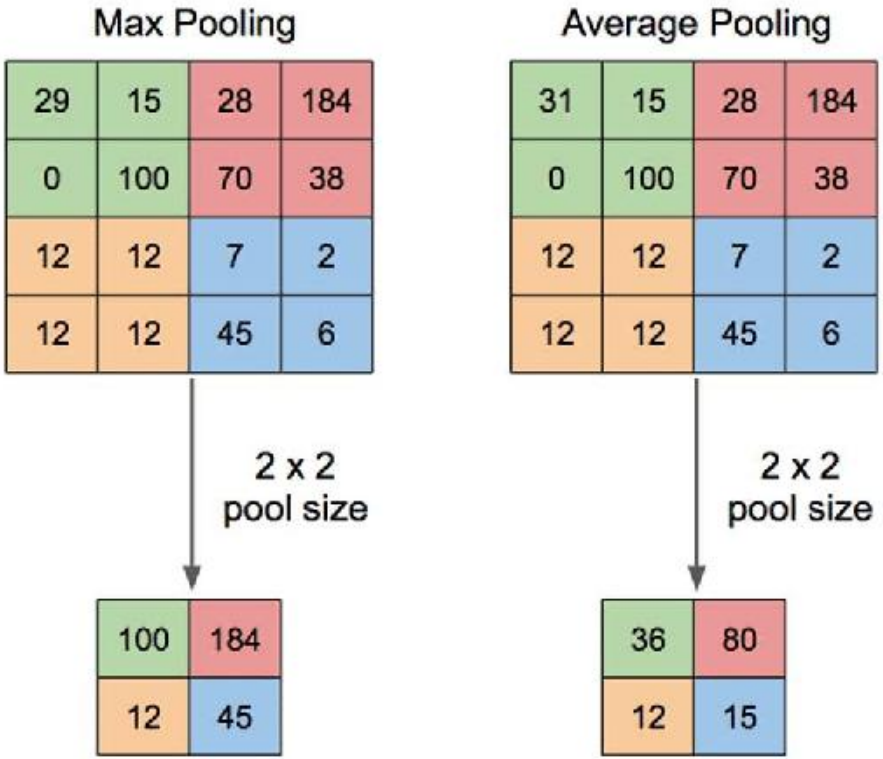
Max Pooling
29 15 28 184
0 100 70 38
12 12 7 2
12 12 45 6
2 x 2
pool size
100 184
12 45
Average Pooling
31 15 28 184
0 100 70 38
12 12 7 2
12 12 45 6
2 x 2
pool size
36 80
12 15

Flatten

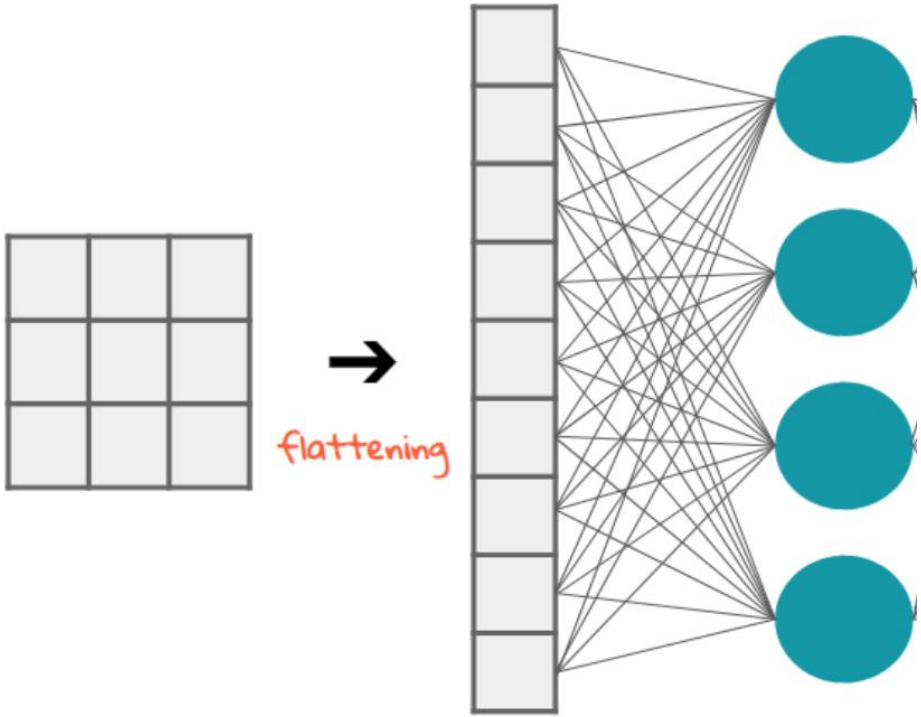

Aprender de los datos: Capa Convolucional

- Capa detectora de bordes
- Capa detectora de partes de caras
- Capa detectora de caras enteras

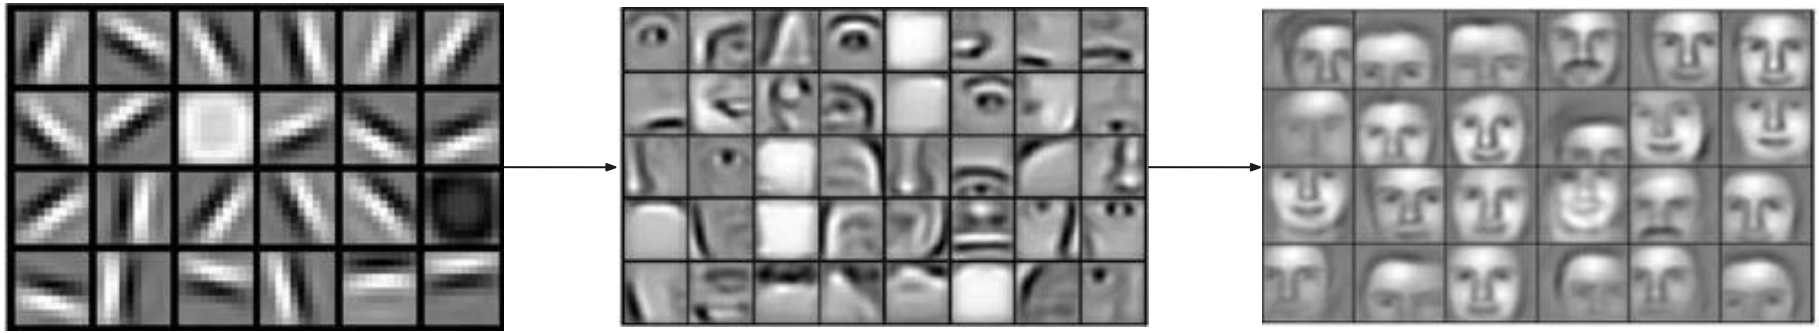

Aprender de los datos: Capa Convolucional

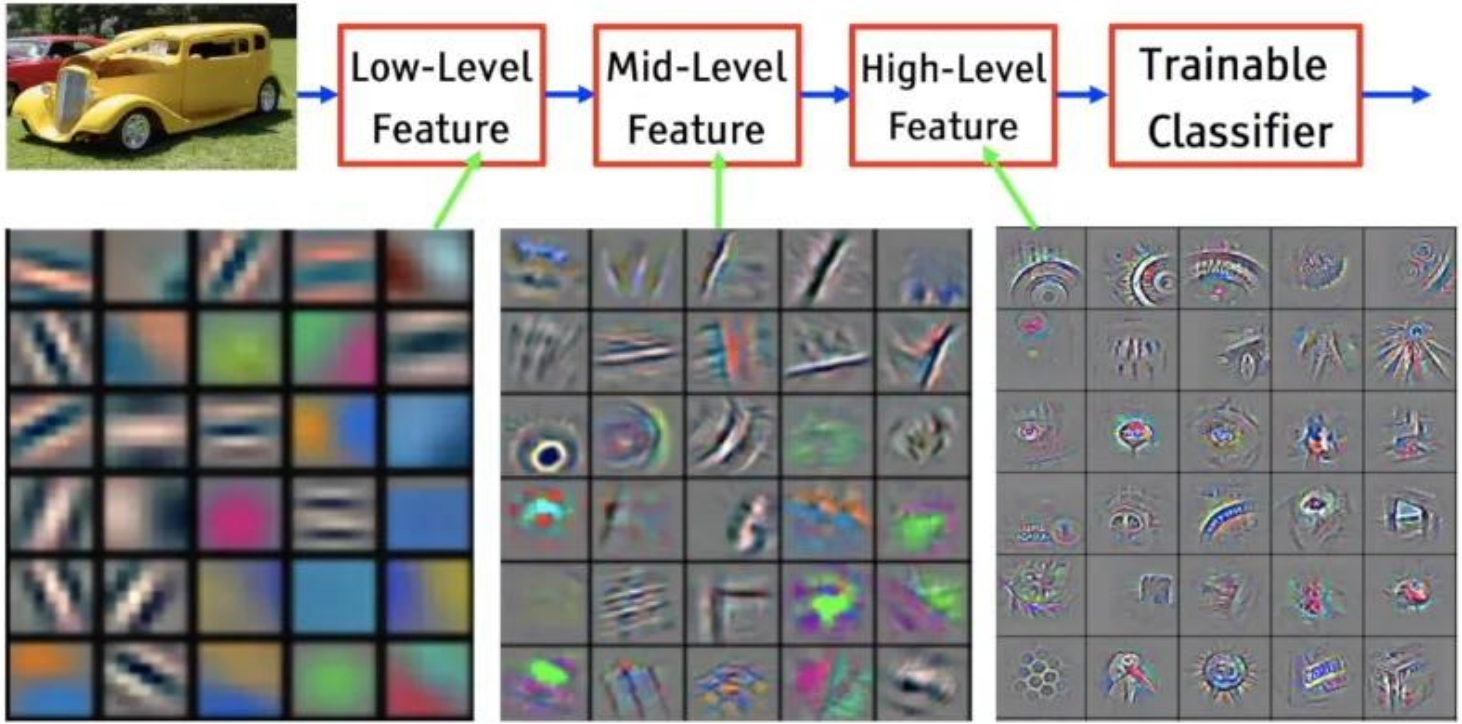

Redes Neuronales Convolucionales (CNNs)

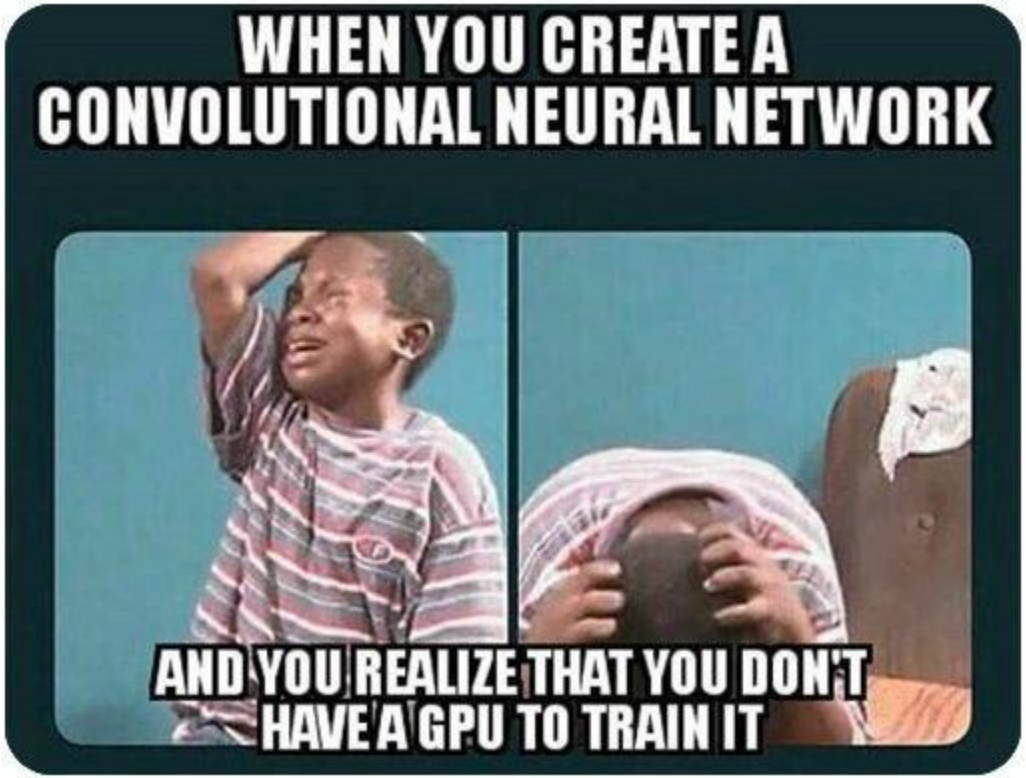

Clasificación de imágenes
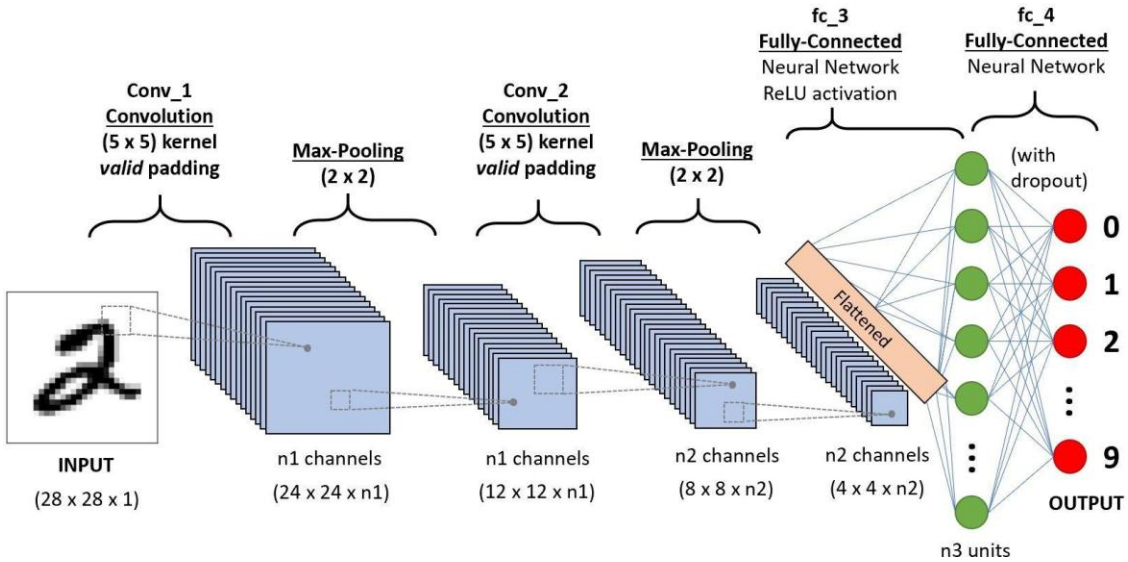
El esquema de las redes para clasificación y, en general, para procesamiento de imágenes, consta de una primera etapa con capas convolucionales y de pooling para la extracción de características, seguida de capas densas para la clasificación final.