Introducción a la detección de objetos

Detección de objetos

La detección de objetos es una tarea de visión por computadora que identifica y localiza elementos dentro de una imagen o video, dibujando un recuadro (bounding box) alrededor de cada uno y asignándole una etiqueta o clase.

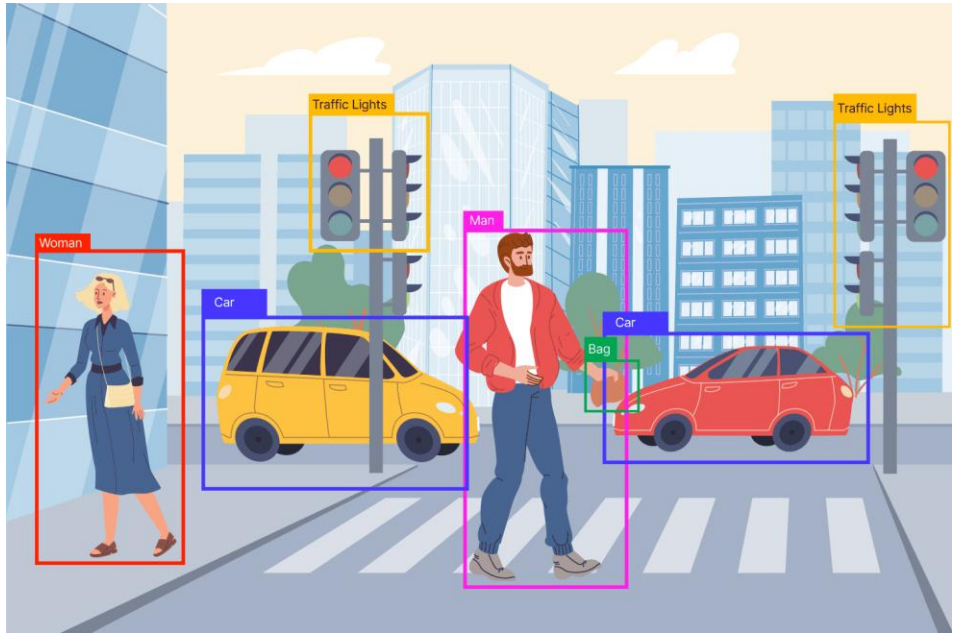

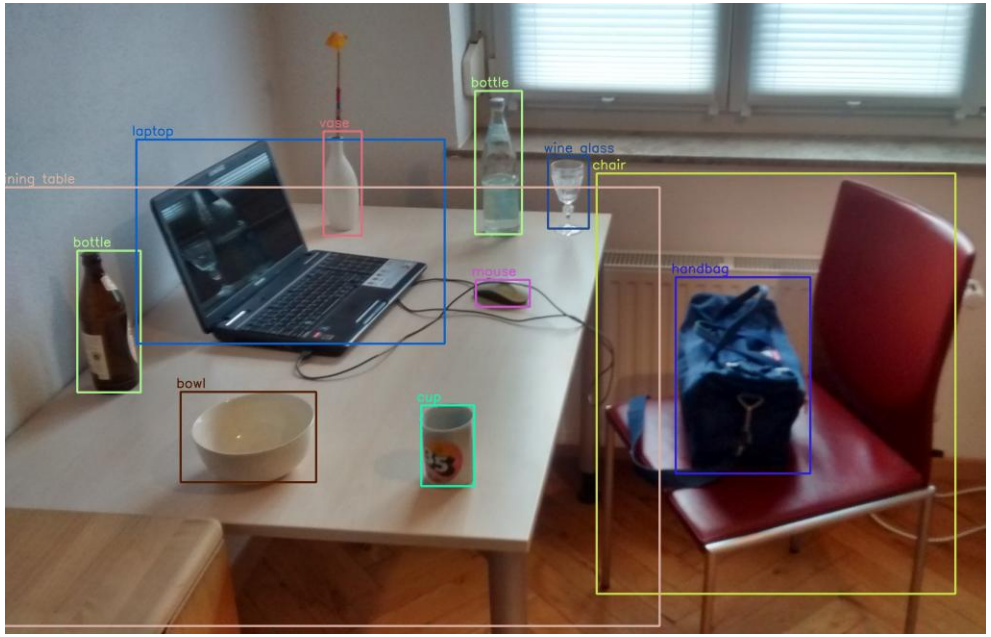

Detección de objetos

¿Por qué es importante?
Permite que los sistemas “entiendan” su entorno visual, no solo que lo vean.

Es una pieza clave en aplicaciones modernas como:

- Vehículos autónomos
- Vigilancia inteligente
- Robots
- Contadores automáticos de personas o productos

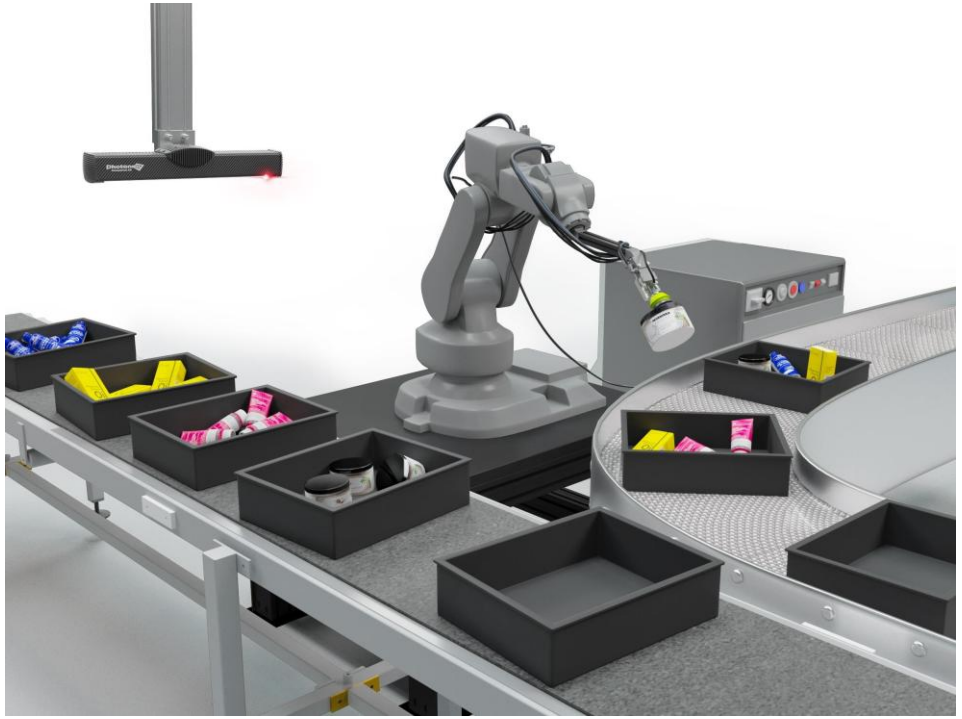

Detección de objetos

Is this a dog?

Image Classification

What is there in image and where?

Object Detection

Which pixels belong to which object?

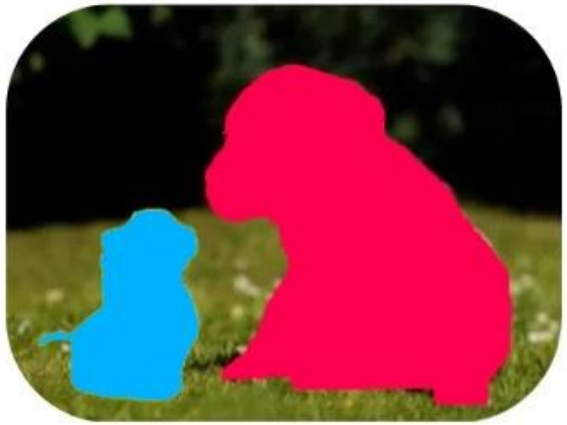

Image Segmentation

Bounding Box

Los formatos más comunes son:

- **xyxy**: (x_min, y_min, x_max, y_max)
- **xywh**: (x_centro, y_centro, ancho, alto)

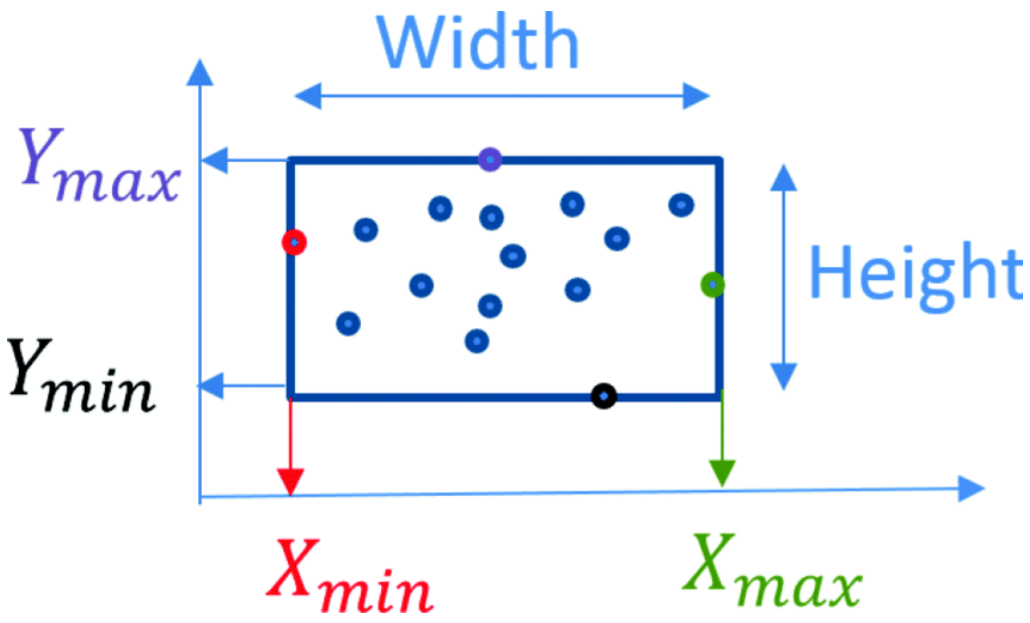

Métricas

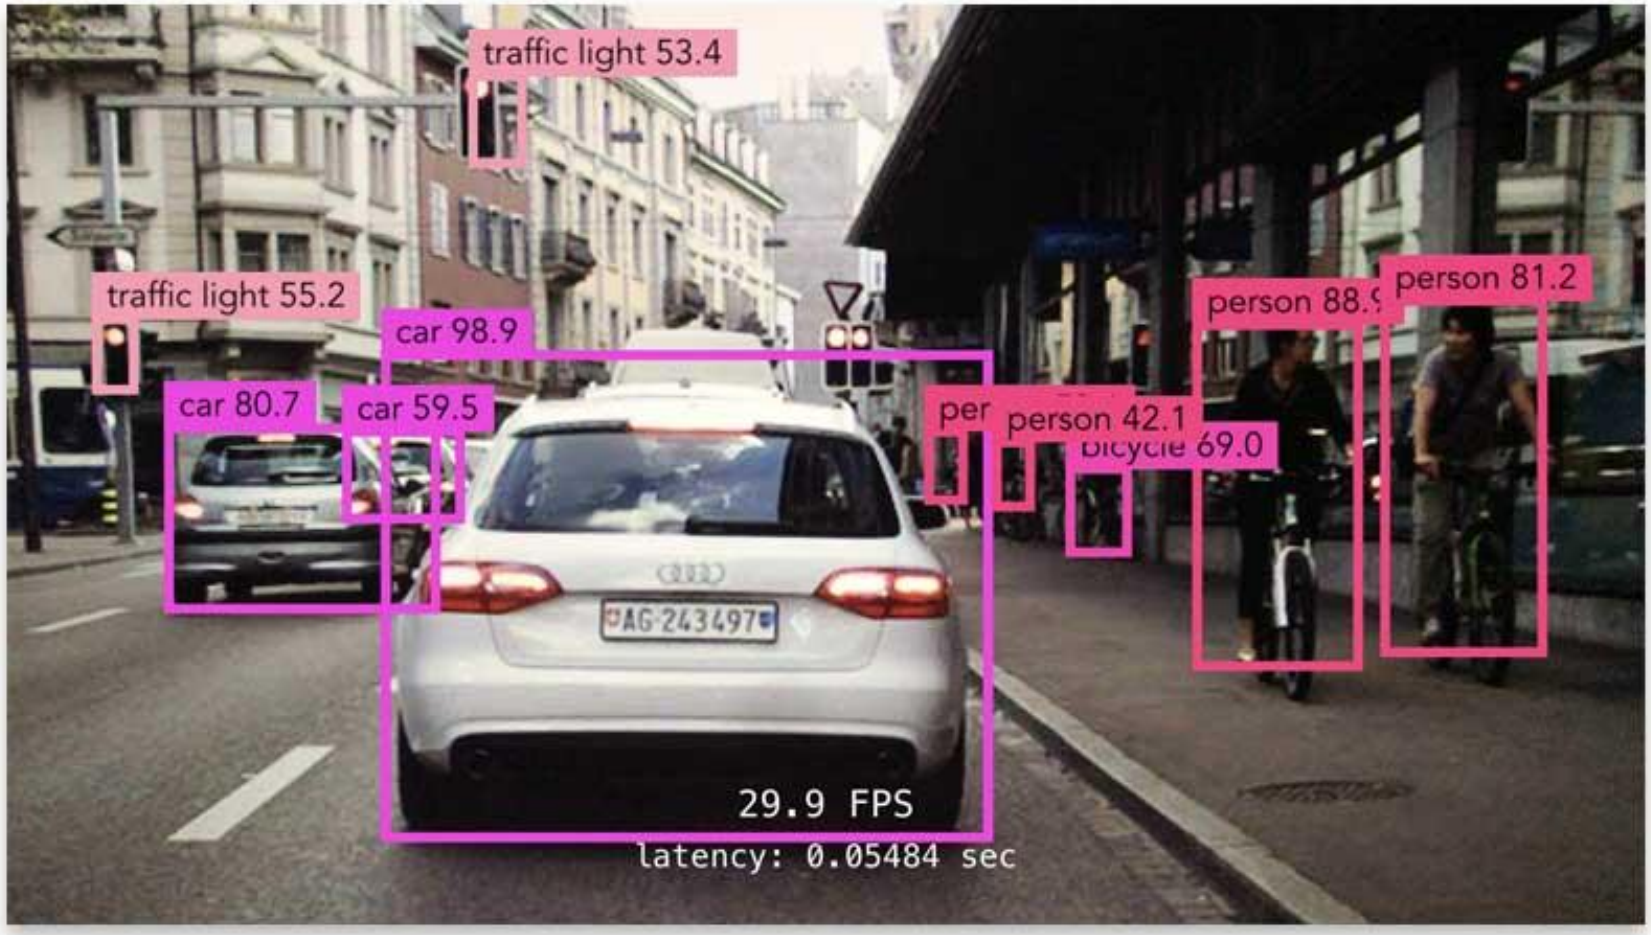
traffic light 53.4
traffic light 55.2
car 98.9
car 80.7
car 59.5
person 42.1
person 81.2
29.9 FPS
latency: 0.05484 sec

Métricas

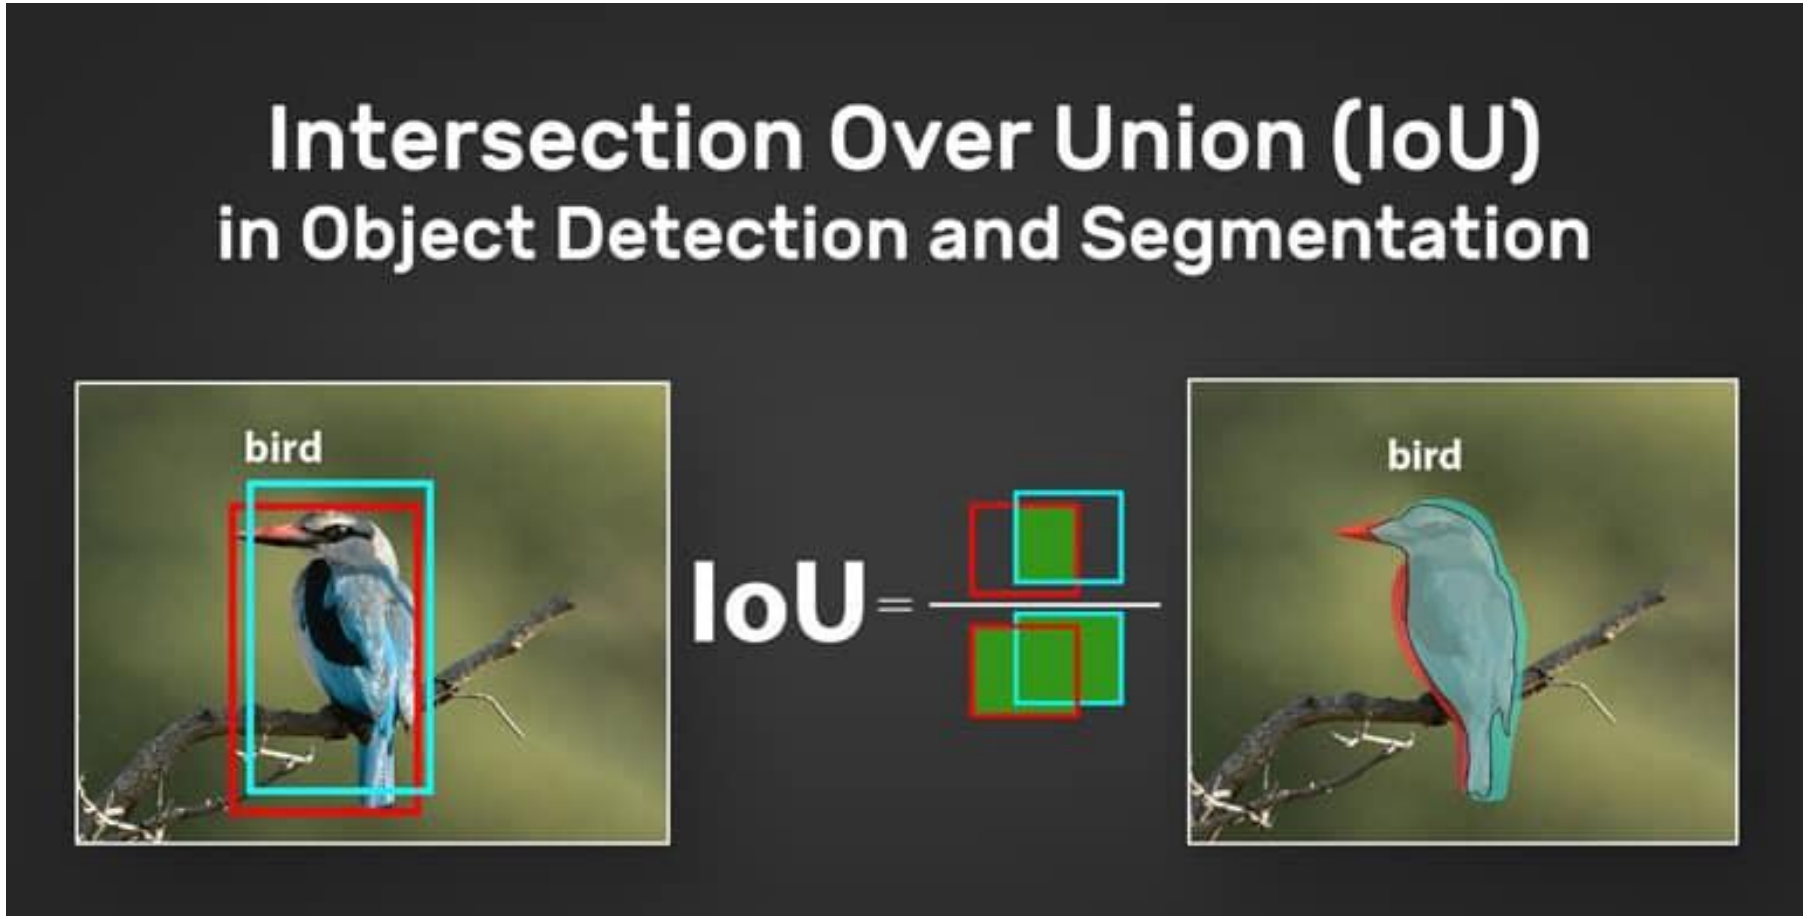
Intersection Over Union (IoU)
in Object Detection and Segmentation
bird
IoU =
bird

Primeros modelos
(doble etapa)

MODELO R-CNN (2014):
ARQUITECTURA Y FLUJO DE DETECCIÓN

1. IMAGEN DE ENTRADA

2. GENERACIÓN DE PROPUESTAS DE REGIÓN

SELECTIVE SEARCH

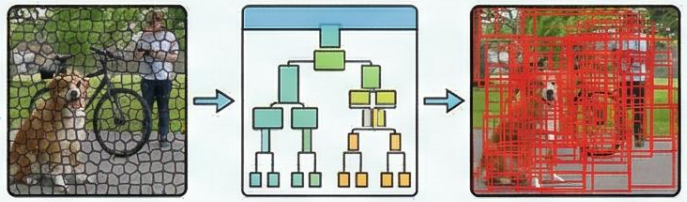

SEGMENTACIÓN INICIAL → AGRUPAMIENTO JERÁRQUICO (color y textura) → SALIDA DE SELECTIVE SEARCH (~2000 imagen)

Combina regiones similares para proponer ubicaciones candidatas

3-4. RECORTE Y REDIMENSIONAMIENTO

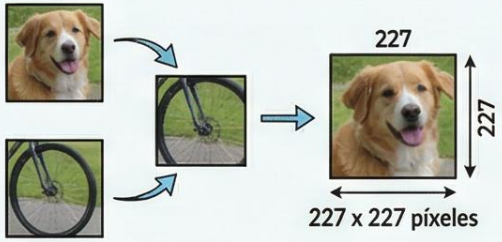

Introduce distorsión geométrica para ajustarse a AlexNet

5. EXTRACCIÓN DE CARACTERÍSTICAS CON CNN (ALEXNET)

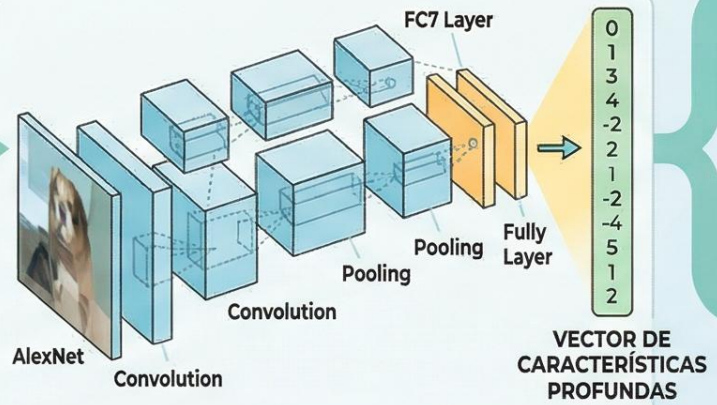

6-7. CLASIFICACIÓN CON SVM

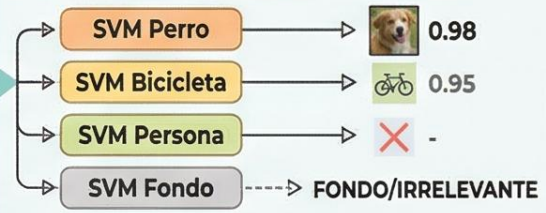

8. REGRESIÓN DE BOUNDING BOXES

REPETICIÓN ~2000 VECES POR IMAGEN

DESVENTAJA: ALTA LENTITUD

10. SUPRESIÓN DE NO MÁXIMOS (NMS)

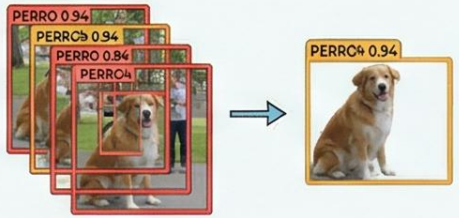

Elimina detecciones duplicadas y redundantes

11. SALIDA FINAL

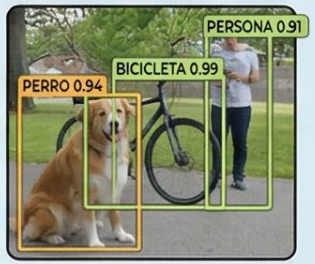

¿CÓMO SE ENTRENA? (MULTI-ETAPA)

Pre-entrenamiento ImageNet → Ajuste fino de CNN → Entrenamiento SVM → Entrenamiento Regresores BB

IMPORTANCIA HISTÓRICA

- Demostró el poder de las características profundas de CNN para detección.
- Superó a métodos clásicos como DPM.

VENTAJAS PRINCIPALES

- Aumento significativo en precisión.
- Introducción de CNNs en detección.

DESVENTAJAS PRINCIPALES

- Muy lento (inferencia secuencial).
- Entrenamiento complejo y multi-fase.
- Alto almacenamiento de características.

1. ENTRADA: IMAGEN ORIGINAL

Imagen completa sin saber ubicación ni cantidad de objetos.

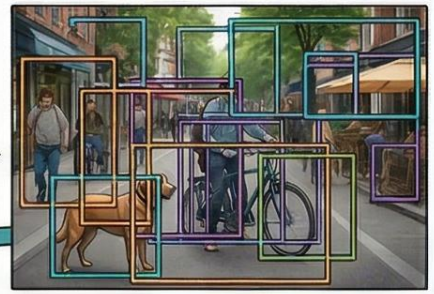

2. GENERACIÓN DE PROPUESTAS DE REGIÓN (SELECTIVE SEARCH)

- ~2000 regiones candidatas.
- Cajas de distintos tamaños.
- Limitación: Sigue siendo lento.

DIFERENCIA CLAVE CON R-CNN

R-CNN
~2000 pasadas de CNN por imagen, lento

Fast R-CNN
1 única pasada de CNN por imagen, eficiente

3. PASO CLAVE: UNA SOLA PASADA POR LA CNN

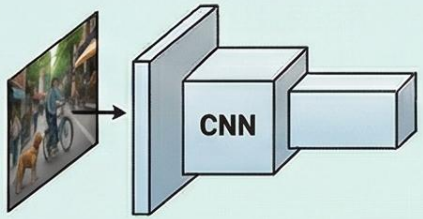

Imagen Completa -> CNN -> Feature Map.
Ahotro maxivo de cómputa.

4. PROYECCIÓN DE REGIONES

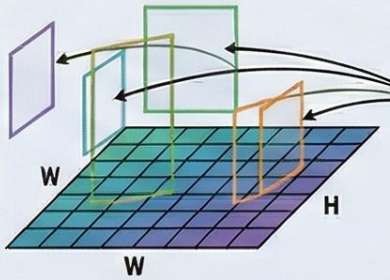

FEATURE MAP
(MAPA DE CARACTERÍSTICAS)
Conserva estructura especial.
Versión comprimida e informativa
(cj. 1000x600 -> 62x37x512).

5. ROI POOLING (EL CORAZÓN DEL MODELO)

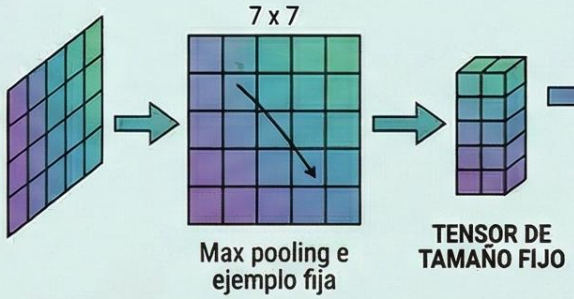

Divide región en grilla fija y aplica pooling.
Convierte cualquier región en vector estándar.
Permite entradas de distintos tamaños.

6. CAPAS COMPLETAMENTE CONECTADAS (FC LAYERS)

Ssa softmax r dentro de la red para predecir probabilidades de clase y fondo (background).

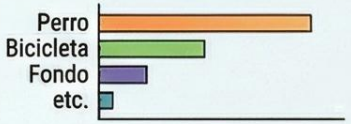

7. CLASIFICACIÓN (SOFTMAX INTEGRADO)

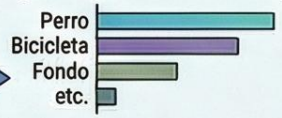

Usa softmax dentro de la red para predecir probabilidades de clase y fondo (background).

Eficiente ioop for al0 regions usn as feature mapo.

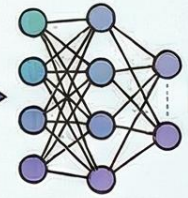

6. CAPAS COMPLETAMET. CONECTADAS (FC LAYERS)

Se aplana y aprende rep-esentaciones para clasificación y localización.

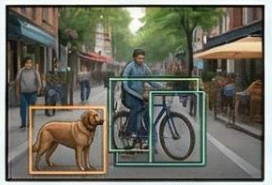

8. REGRESIÓN DE

Ajuste y refinamiento de la caja paralela a la clasificación.

4. PROYECCIÓN DE REGIONES

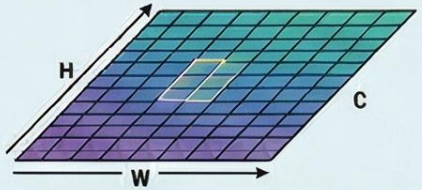

Conserva estructura espacial.
Versión comprimida e informativa
(ej. 1000x600 -> 62x37x312).

DIFERENCIA CLAVE CON R-CNN

R-CNN
~2000 pasadas de CNN por imagen, lento

Fast R-CNN
1 única pasada de CNN por imagen, eficiente

ENTRENAMIENTO

R-CNN: multi-stage (CNN+SVM+regresión).

Fast R-CNN: Entrenamiento End-to-End (casi completo).

Una sola función de pérdida conjunta (Clasificación + Localización).

10. NON-MAXIMUM SUPPRESSION (NMS)

Elimina duplicados y seleccions las mejores cajas.

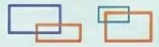

LIMITACIÓN IMPORTANTE

Sigue usando Selective Search (Cuello de botella en velocidad).

11. SALIDA FINAL

11. SALIDA FINAL

Clase, bounding box refinada y score para cada objeto.

YOLO

YOLO

YOLO (You Only Look Once) es una familia de modelos de detección de objetos que realiza la detección en una sola pasada por la red neuronal, logrando alta velocidad y buena precisión. Mientras otros enfoques procesaban una imagen en varias etapas, YOLO predice directamente las posiciones y clases de todos los objetos en un solo paso.

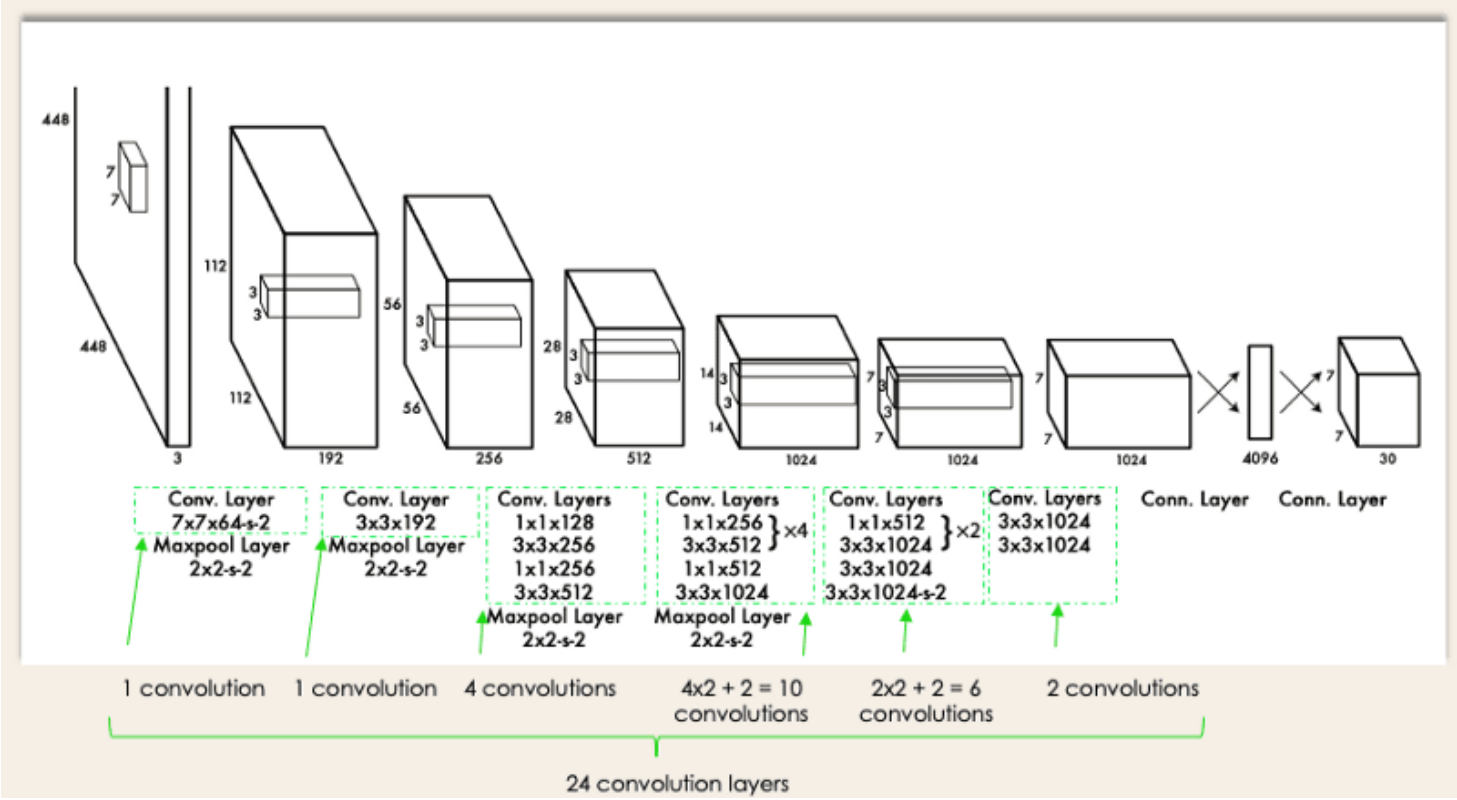

YOLO

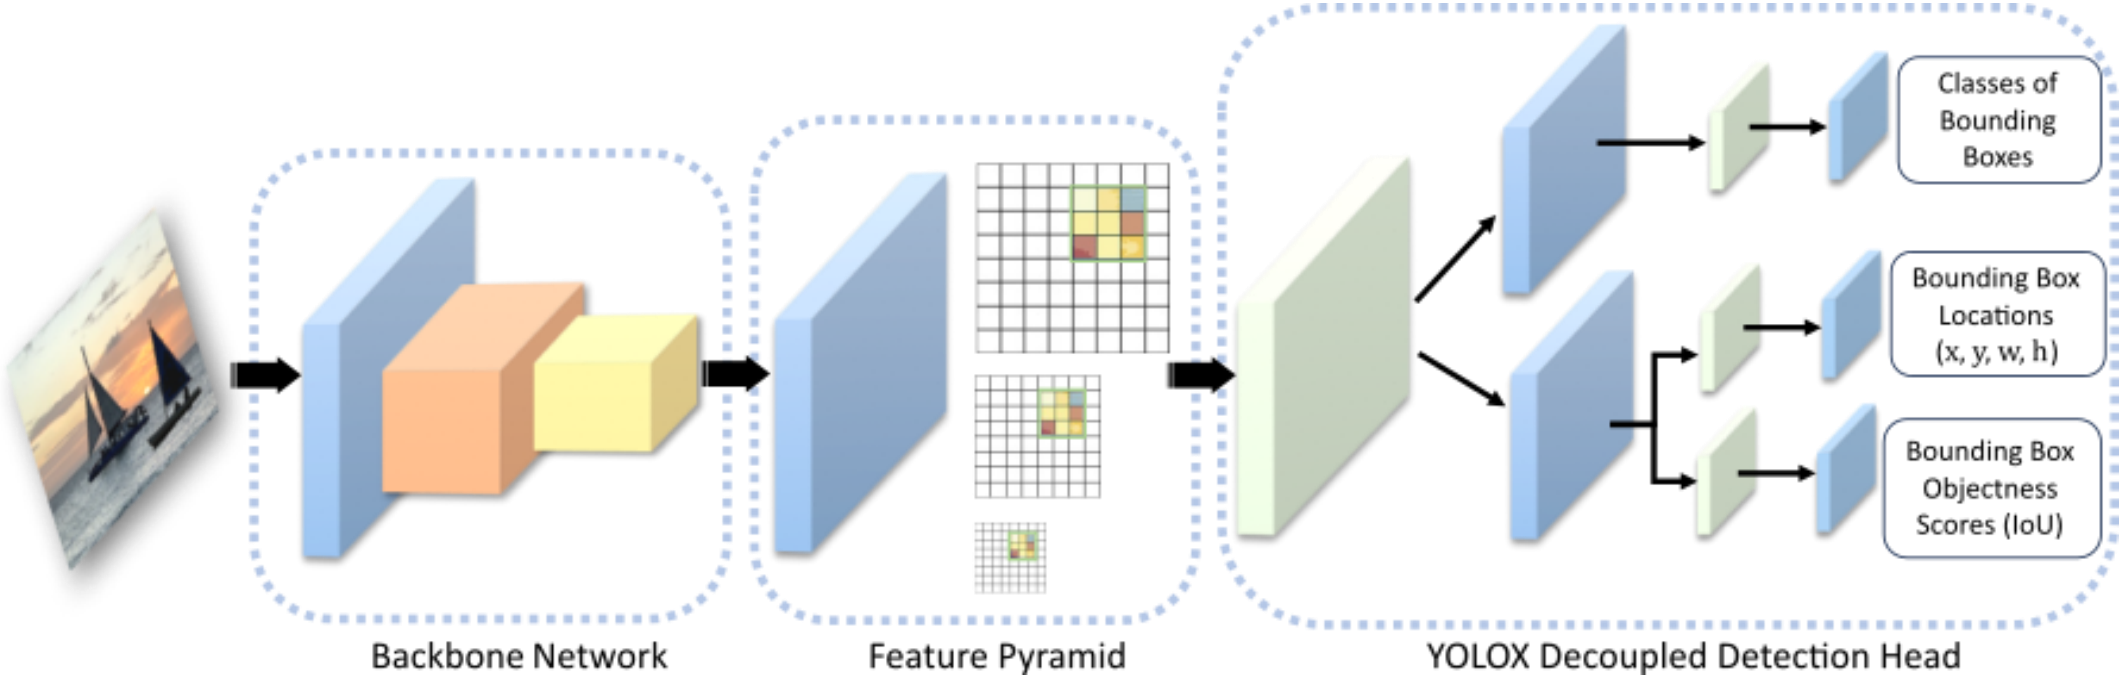
Classes of Bounding Boxes
Bounding Box Locations (x, y, w, h)
Bounding Box Objectness Scores (IoU)
Backbone Network
Feature Pyramid
YOLOX Decoupled Detection Head

YOLO

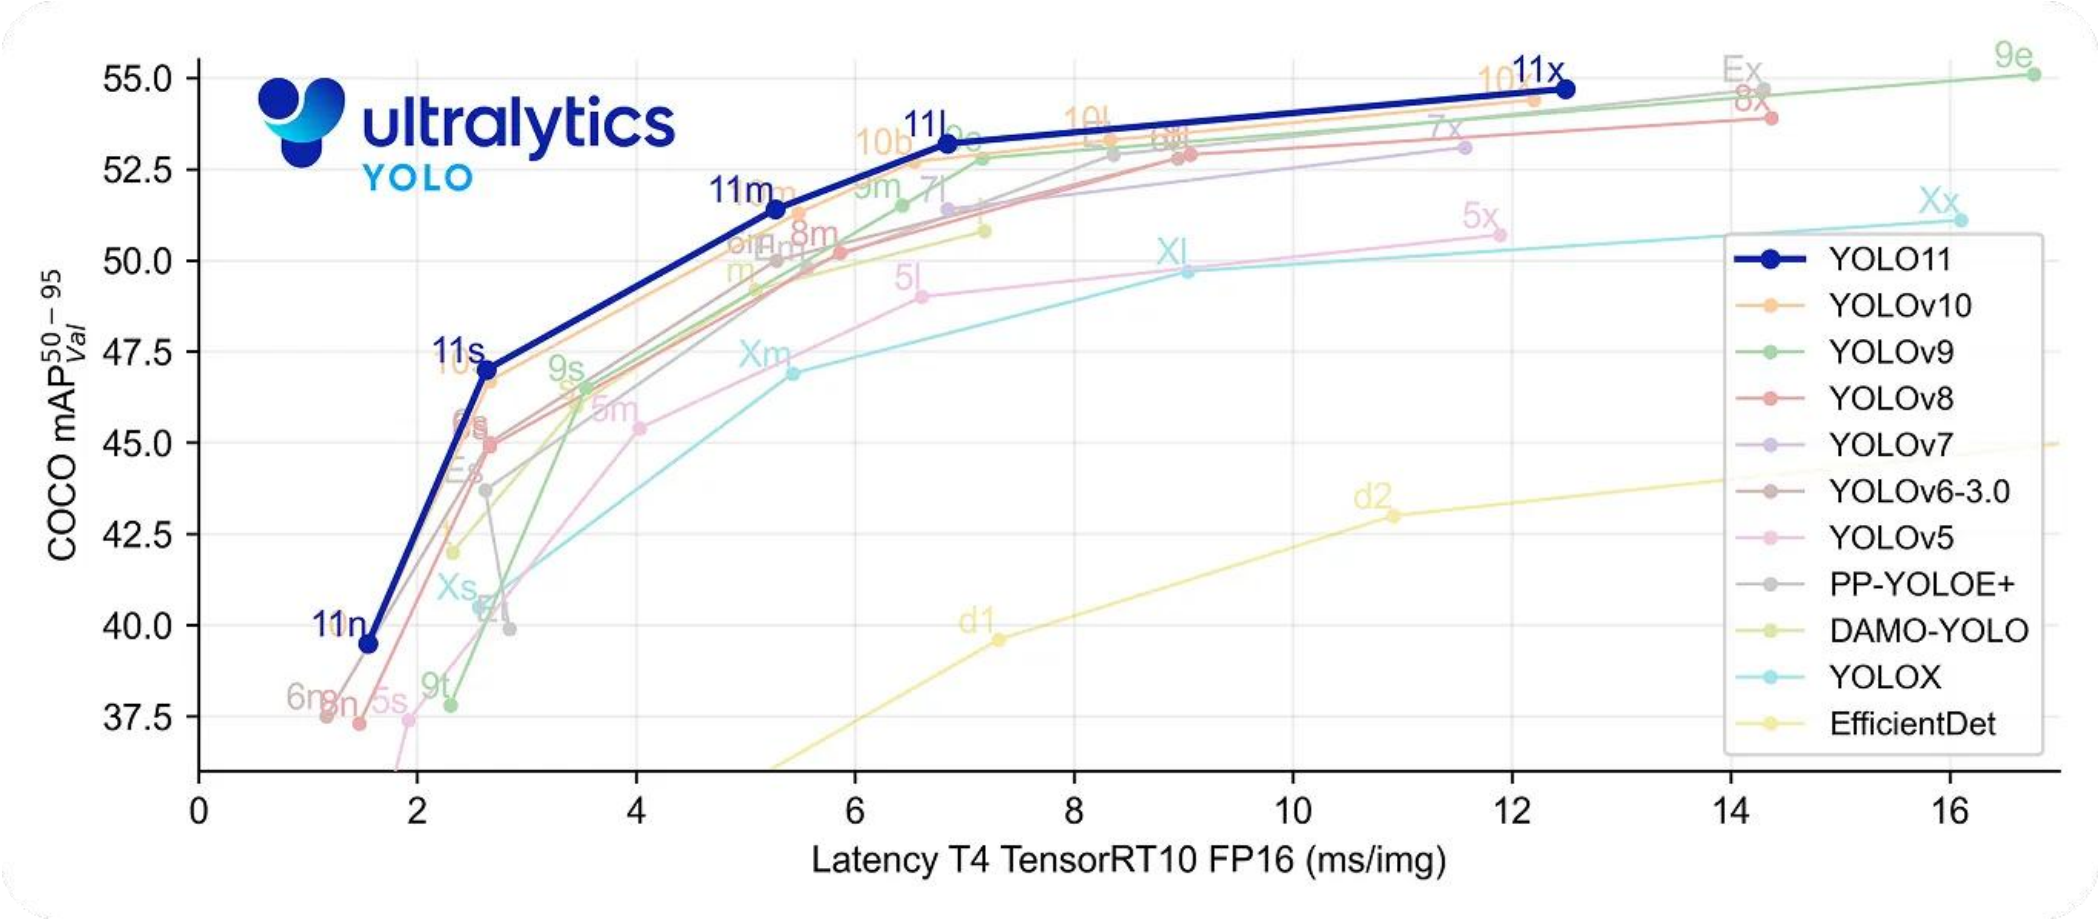
ultralytics
YOLO
COCO mAP$^{50-95}_{Val}$
Latency T4 TensorRT10 FP16 (ms/img)
55.0
52.5
50.0
47.5
45.0
42.5
40.0
37.5
0
2
4
6
8
10
12
14
16
11n
11s
11m
11l
11x
YOLO11
YOLOv10
YOLOv9
YOLOv8
YOLOv7
YOLOv6-3.0
YOLOv5
PP-YOLOE+
DAMO-YOLO
YOLOX
EfficientDet

Plataformas Edge

```python
import RPi.GPIO as GPIO
import time

ledPin= 21

GPIO.setmode(GPIO.BCM)
GPIO.setup(ledPin , GPIO.OUT)

while True:
  GPIO.output(ledPin , GPIO.HIGH)
  time.sleep(1)
  GPIO.output(ledPin , GPIO.LOW)
  time.sleep(1)
```

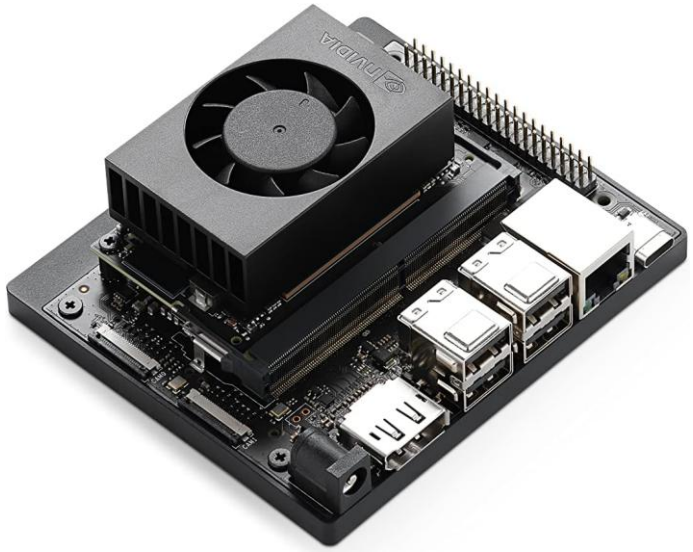

Plataformas Edge

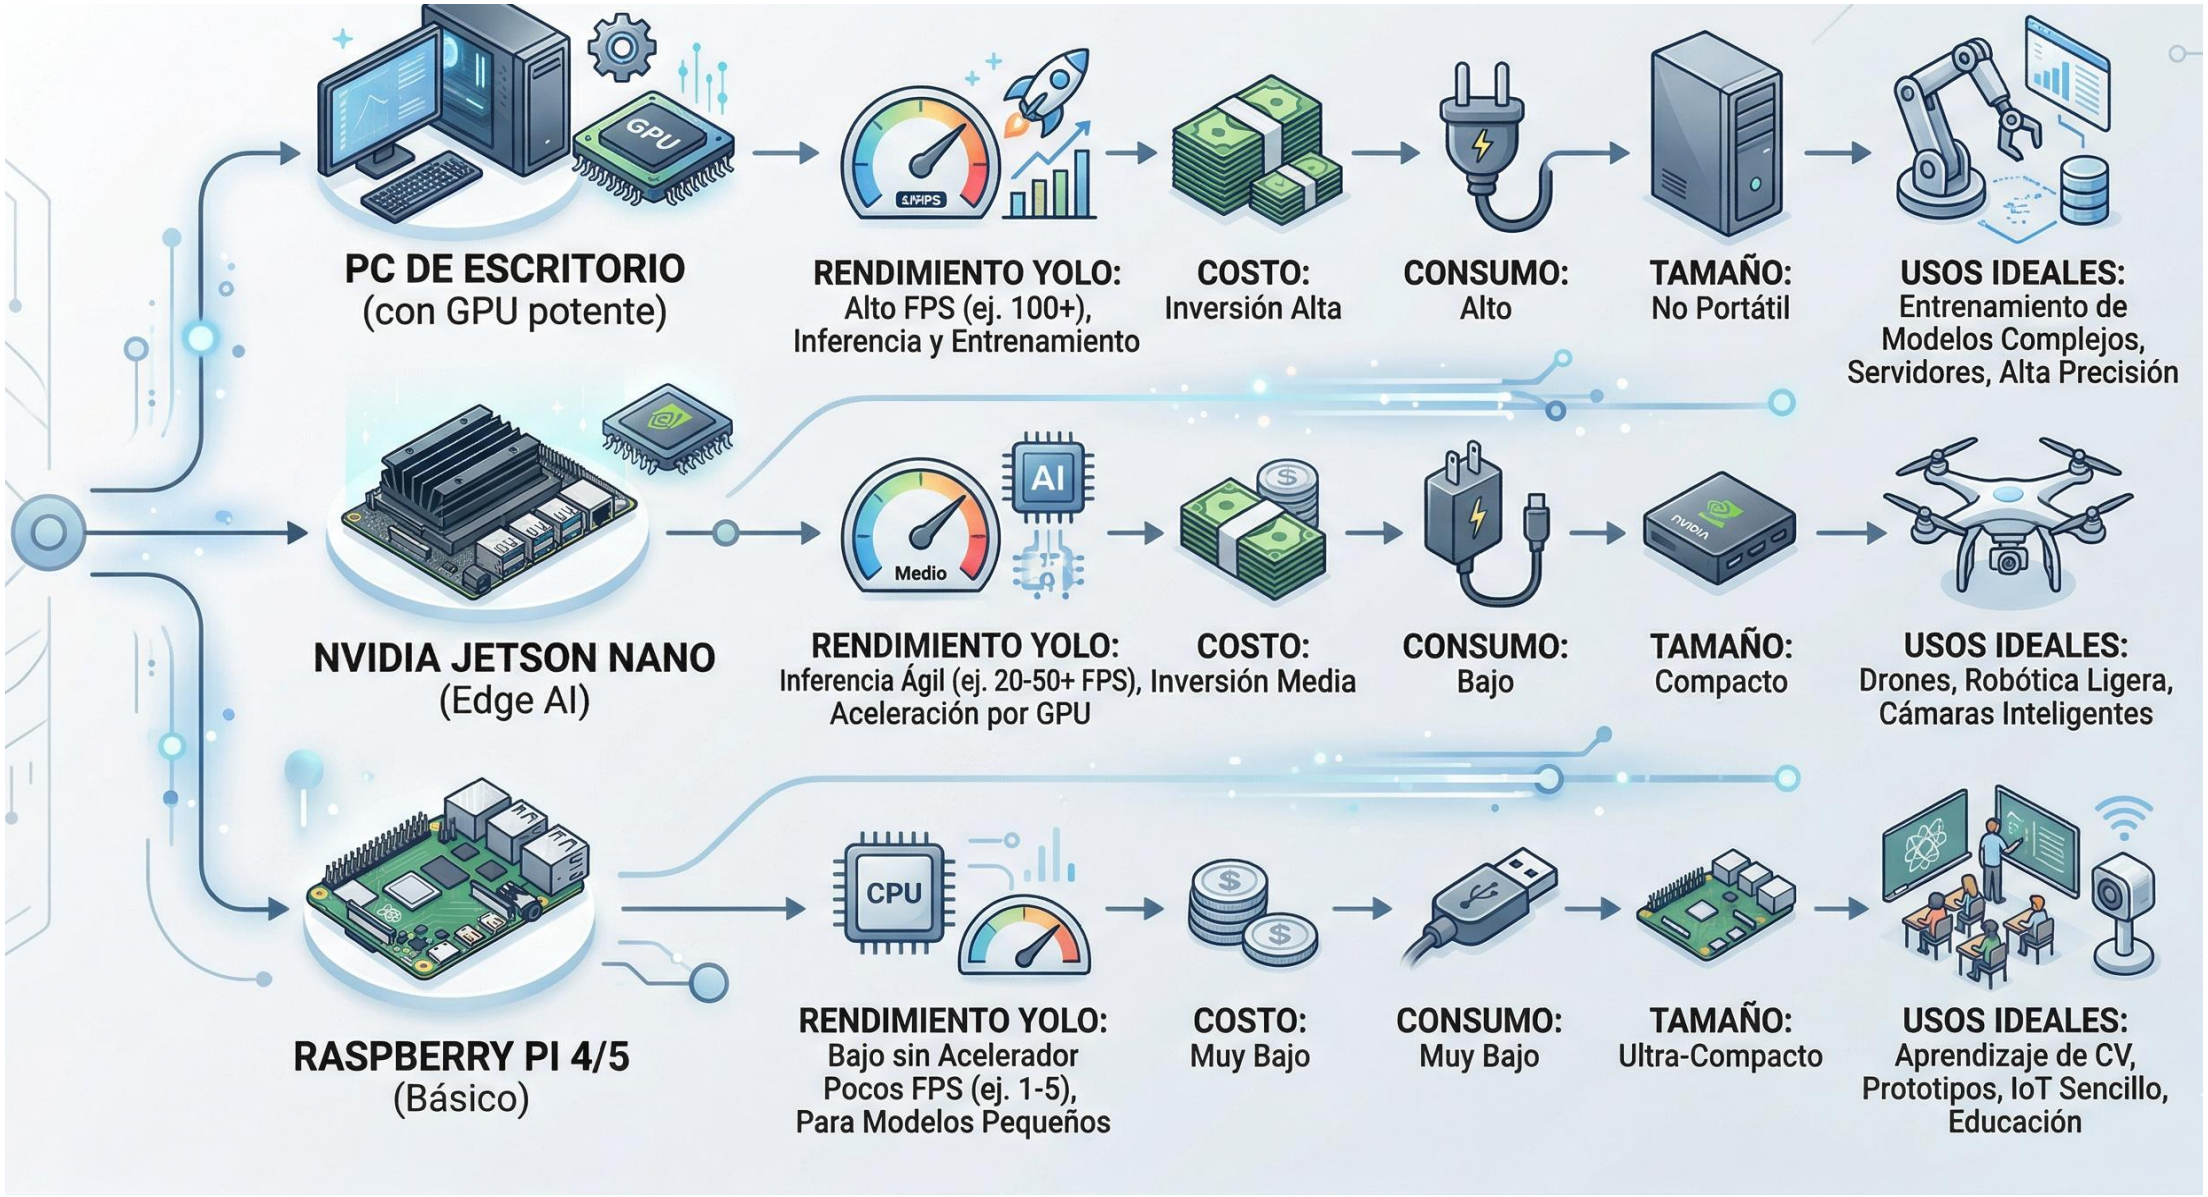

GUÍA VISUAL: COMPARATIVA DE ESCALAS YOLO Y DISPOSITIVOS DE DESPLIEGUE

¿QUÉ SON LAS ESCALAS DE YOLO?

Variaciones en tamaño de modelo para equilibrar **PRECISIÓN** y **VELOCIDAD** en distintos hardwares.

YOLO

Param: Muy Bajo → mAP: Bajo (ej. ~32) → FPS: Bajo (ej. ~10)

YOLO Nano

PEQUEÑO TAMAÑO, MÁXIMA VELOCIDAD

Param:

Parames: Muy Bajo

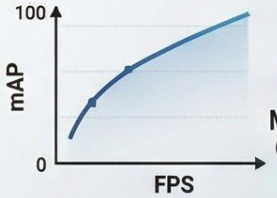

mAP: Bajo (ej. ~32)

Muy Alto (ej. ~110)

RASPBERRY PI (4/5)

IDEAL PARA DISPOSITIVOS EDGE DE BAJO CONSUMO

YOLO Small

EQUILIBRIO BÁSICO

Param:

Parames: Bajo

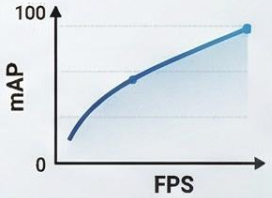

mAP: Medio (ej. ~38)

Alto (ej. ~80)

JETSON NANO

BUEN RENDIMIENTO PARA IA EN TIEMPO REAL

YOLO Medium

RENDIMIENTO VERSÁTIL

Param:

Parames: Medio

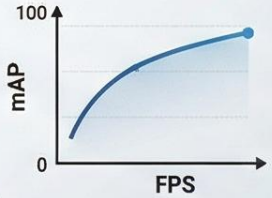

mAP: Alto (ej. ~45)

Medio (ej. ~40)

PC CON GPU DEDICADA

(NVIDIA RTX 3060 / RTX 4060)

BALANCE PERFECTO PARA SISTEMAS DE ESCRITORIO

YOLO Large

ALTA PRECISIÓN, RENDIMIENTO SÓLIDO

Param:

Parames: Alto

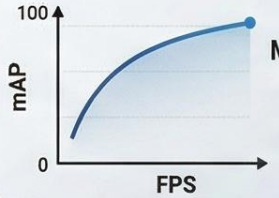

mAP: Muy Alto (ej. ~51)

Bajo (ej. ~25)

PC CON GPU DEDICADA POTENTE

(NVIDIA RTX 3080 / RTX 4080)

PRECISIÓN SUPERIOR PARA INFERENCIA EXIGENTE

YOLO XL

MÁXIMA PRECISIÓN, REQUIERE HARDWARE ROBUSTO

Param:

Parames: Muy Alto

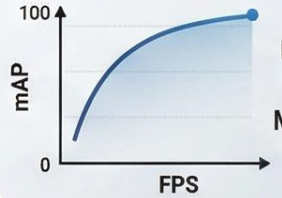

mAP: Máximo (ej. ~54)

Muy Bajo (ej. ~15)

SERVIDOR / CLUSTER DE IA

(H100 / A100 / RTX 4090)

IDEAL PARA INVESTIGACIÓN Y ENTORNOS DE PRODUCCIÓN OFF-LINE

Entrenamiento custom