Detección de anomalías en máquinaria industrial mediante espectrogramas y redes convolucionales profundas

Carlos Rivas
Facultad de Ingeniería
Universidad de Buenos Aires (FIUBA)
Buenos Aires, Argentina
carlos.rivas@fi.uba.ar

Cesar Mejia
Facultad de Ingeniería
Universidad de Buenos Aires (FIUBA)
Buenos Aires, Argentina
cemejia555@gmail.com

***Resumen*—Este trabajo presenta un sistema de detección de anomalías acústicas en ventiladores industriales basado en aprendizaje profundo. Las grabaciones de audio provenientes de cuatro unidades de ventilador que operan bajo condiciones de ruido de fondo con relación señal-ruido de $-6\,\mathrm{dB}$ son transformadas en imágenes de espectrogramas Mel y procesadas por una red convolucional ResNet-18 ajustada mediante transfer learning selectivo. Para gestionar el desbalance entre clases (4.075 muestras normales frente a 1.475 anómalas) se aplica una función de pérdida ponderada por clase. El modelo alcanza una exactitud global del 95 %, un recall de anomalías del 95 % y un F1-score macro promedio de 0,93 sobre el conjunto de validación. La curva ROC reporta un área bajo la curva (AUC) de 0,86. Los resultados demuestran la viabilidad de reformular la detección de anomalías como un problema de clasificación de imágenes, aprovechando arquitecturas consolidadas de visión por computadora en escenarios de mantenimiento predictivo industrial.**

***Index Terms*—detección de anomalías, ventiladores industriales, espectrograma Mel, ResNet-18, transfer learning, mantenimiento predictivo, aprendizaje profundo**

I. Introducción

I-A. Contexto del problema

La detección temprana de fallas en maquinaria industrial es un problema de gran relevancia en entornos productivos modernos. En sectores como manufactura, energía o logística, una falla inesperada puede generar interrupciones en la operación, pérdidas económicas significativas y, en algunos casos, riesgos para la seguridad. Por este motivo, el desarrollo de sistemas de monitoreo automático es un área activa de investigación y aplicación.

Tradicionalmente, este tipo de problemas se aborda mediante sensores específicos o inspecciones manuales. Sin embargo, estas soluciones presentan limitaciones, ya sea por su costo, su dificultad de implementación a gran escala o su dependencia de intervención humana.

En este contexto, el análisis de señales acústicas surge como una alternativa interesante. Las máquinas generan patrones de sonido característicos durante su funcionamiento, y cambios en estos patrones pueden indicar la presencia de anomalías. Este enfoque tiene la ventaja de ser no invasivo y de poder implementarse con sensores relativamente simples.

En los últimos años, el uso de técnicas de deep learning ha permitido mejorar significativamente el desempeño de los sistemas de detección automática. En particular, una estrategia ampliamente adoptada consiste en transformar las señales de audio en representaciones visuales, como espectrogramas, lo que permite utilizar modelos de visión por computadora.

Este enfoque resulta especialmente atractivo debido a la disponibilidad de arquitecturas preentrenadas sobre grandes datasets de imágenes, como ImageNet. Mediante transfer learning, es posible adaptar estos modelos a nuevas tareas con un costo computacional relativamente bajo.

En este trabajo se propone un sistema para la detección de anomalías en ventiladores industriales a partir de audio, utilizando espectrogramas como entrada y una red convolucional profunda del tipo ResNet. El objetivo es evaluar la capacidad del modelo para distinguir entre condiciones normales y anómalas, incluso en presencia de ruido.

I-B. Trabajo relacionado

El referente directo de este trabajo es el sistema presentado por Purohit *et al.* [1], quienes recopilaron el dataset MIMII (*Malfunctioning Industrial Machine Investigation and Inspection*), que incluye grabaciones de cuatro tipos de maquinaria industrial bajo distintos niveles de ruido de fondo. Su baseline de detección empleó un autoencoder denso entrenado exclusivamente con muestras normales, alcanzando un AUC promedio de aproximadamente 0,65 bajo condiciones de $-6\,\mathrm{dB}$ de SNR, condición tomada aquí como referencia de dificultad.

Otros datasets como ToyADMOS han sido propuestos para estudiar anomalías acústicas en máquinas de menor escala [2].

I-C. Objetivo

El objetivo principal es desarrollar y validar un sistema de clasificación binaria (normal/anómalo) que, a partir de espectrogramas Mel obtenidos de grabaciones de audio industrial, utilice transfer learning sobre ResNet-18 [3] para detectar anomalías acústicas en ventiladores con alta sensibilidad. Se

prioriza la minimización de falsos negativos —anomalías que el sistema no detecta—, ya que en un contexto de mantenimiento predictivo este tipo de error tiene mayor costo operativo que una falsa alarma.

II. Metodología, Diseño y Desarrollo

II-A. Descripción del dataset

Se utilizó el subconjunto de ventiladores del dataset MIMII disponible públicamente en Zenodo con nivel de ruido de fondo de -6 dB. El conjunto contiene grabaciones de cuatro unidades de ventilador industrial identificadas como `id_00`, `id_02`, `id_04` e `id_06`. Cada archivo de audio tiene una duración de 10 segundos grabado a 16 kHz con ruido de fábrica superpuesto. La distribución resultante es 4.075 archivos normales y 1.475 anómalos, generando un desbalance de clases de aproximadamente 2,76:1, como se aprecia en la Fig. 1.

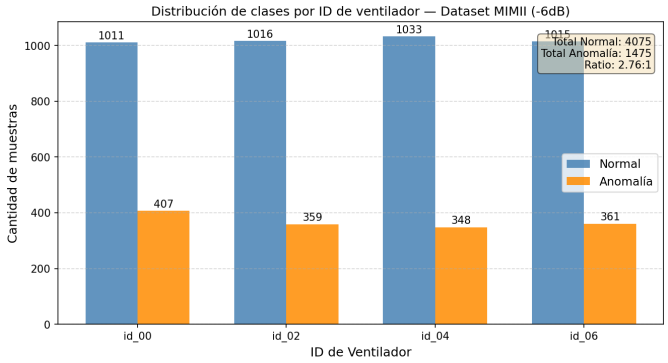

Figura 1. Distribución de muestras por clase y por ID de ventilador. Se observa el desbalance inherente del dataset MIMII (-6 dB).

II-B. Preprocesamiento: conversión a espectrogramas Mel

Las señales de audio no pueden ser utilizadas directamente por redes convolucionales, ya que estas están diseñadas para trabajar con datos bidimensionales. Por este motivo, se realizó una transformación a espectrogramas utilizando la librería *librosa* [4]. La conversión del dominio temporal al dominio tiempo-frecuencia se realizó mediante la función `librosa.feature.melspectrogram` con los hiperparámetros listados en la Tabla I. Las imágenes resultantes se almacenaron como archivos PNG sin ejes ni márgenes (*borderless*), de modo que la red convolucional reciba exclusivamente la información espectral.

Esta representación preserva tanto la distribución de energía frecuencial como su evolución temporal, siendo suficiente para discriminar entre el patrón acústico estacionario de un ventilador normal y las irregularidades frecuenciales características de una anomalía mecánica. La Fig. 2 ilustra la diferencia visual entre ambas condiciones para la unidad `id_00`.

Cuadro I
Hiperparámetros de generación de espectrogramas Mel

Parámetro	**Valor**
Frecuencia de muestreo	16.000 Hz
Número de bandas Mel (*n_mels*)	128
Frecuencia máxima (*fmax*)	8.000 Hz
Escala de amplitud	dB (*power_to_db*)
Resolución de imagen	400×400 px
Mapa de color	*magma*

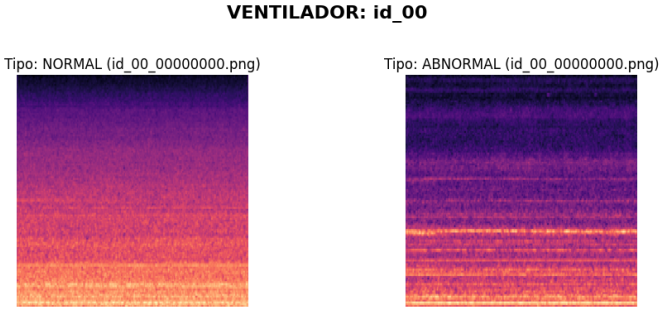

Figura 2. Comparación de espectrogramas Mel: condición normal (izquierda) y condición anómala (derecha) para `id_00`. Se observan diferencias en la distribución de energía en bandas medias y superiores.

II-C. Arquitectura del modelo: ResNet-18 con fine-tuning selectivo

Se adoptó ResNet-18 preentrenada en ImageNet como backbone convolucional. La elección de ResNet-18 por sobre arquitecturas más profundas (ResNet-50, EfficientNet-B4) responde a tres criterios: (1) el tamaño del dataset ($\approx$5.550 imágenes) no justifica la capacidad de redes más grandes que son propensas a sobreajuste; (2) la tarea de clasificación binaria de espectrogramas es relativamente sencilla en términos de complejidad visual; (3) la latencia de inferencia es significativamente menor, lo cual es relevante para aplicaciones de monitoreo continuo en planta.

La estrategia de fine-tuning fue selectiva: se congelaron todos los parámetros excepto el bloque residual final (`layer4`) y la nueva capa fully connected de salida ($512 \rightarrow 2$ neuronas). Las capas iniciales de ResNet aprenden características de bajo nivel (bordes, texturas) transferibles desde ImageNet, mientras que `layer4` aprende representaciones de alto nivel que deben adaptarse a la distribución específica de los espectrogramas industriales. La Fig. 3 muestra la estrategia de fine-tuning.

II-D. Estrategia de entrenamiento

Para abordar el desbalance de clases se utilizó `CrossEntropyLoss` con pesos ponderados, asignando un peso de 2,7 a la clase anómala y 1,0 a la clase normal, proporcionales al inverso de la frecuencia relativa de cada clase. El optimizador fue Adam [5] con tasa de aprendizaje de 1×10^{-4} y regularización L2 (*weight_decay* = 1×10^{-4}). El conjunto de datos se dividió aleatoriamente en 80 % para entrenamiento (4.440 imágenes) y 20 % para validación

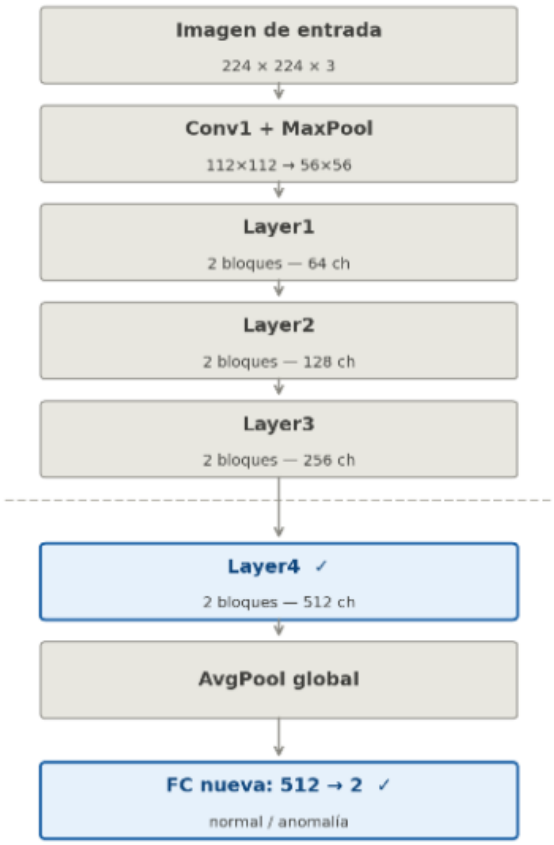

Figura 3. Estrategia de fine-tuning sobre ResNet-18. Las capas `layer1`–`layer3` permanecen congeladas (gris); `layer4` y la nueva FC son entrenables (azul).

(1.110 imágenes). Se entrenaron 10 épocas con batch size de 16, guardando el *checkpoint* con menor *validation loss*. La Tabla II muestra la configuración completa de entrenamiento.

Cuadro II
HIPERPARÁMETROS DE ENTRENAMIENTO

Hiperparámetro	**Valor**
Optimizador	Adam
Tasa de aprendizaje	1×10^{-4}
Regularización L2 (*weight decay*)	1×10^{-4}
Batch size	16
Épocas totales	10
Peso clase anómala	2,7
Peso clase normal	1,0
División entrenamiento / validación	80 % / 20 %
Capas descongeladas	`layer4` + FC

III. RESULTADOS EXPERIMENTALES

III-A. *Curvas de entrenamiento*

El modelo convergió de forma estable a lo largo de las 10 épocas. El mejor checkpoint fue guardado en la época 5 con una validation loss de 0,1463. A partir de la época 6 la *validation loss* comienza a crecer levemente mientras el *training loss* continúa descendiendo, evidenciando el inicio de sobreajuste moderado que justifica la selección del mejor checkpoint en lugar del modelo de la última época (Fig. 4).

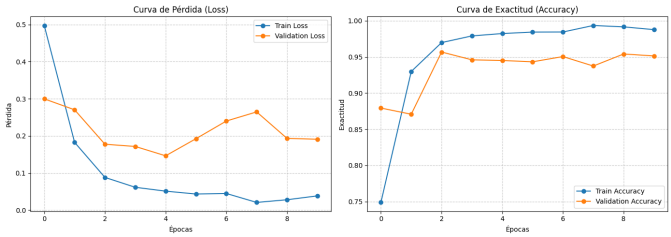

Figura 4. Curvas de pérdida y exactitud por época para los conjuntos de entrenamiento y validación. El mejor modelo se obtiene en la época 5 (línea punteada).

III-B. *Matriz de confusión*

La evaluación sobre el conjunto de validación (2.220 muestras) arrojó la matriz de confusión de la Fig. 5. El modelo detectó correctamente 552 de 581 casos anómalos (verdaderos positivos) y clasificó correctamente 1.546 de 1.639 casos normales (verdaderos negativos). Se registraron 29 falsos negativos (anomalías clasificadas como normales) y 93 falsas alarmas (normales clasificadas como anómalas).

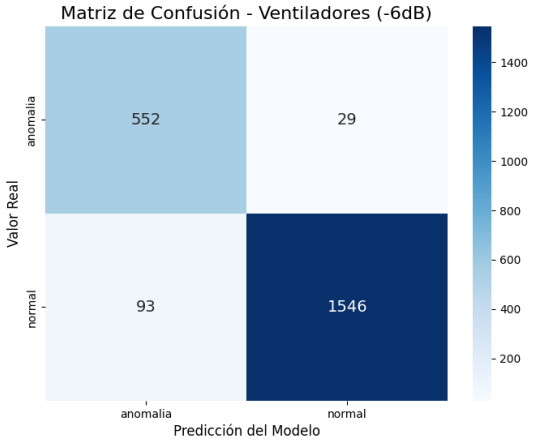

Figura 5. Matriz de confusión sobre el conjunto de validación. TP = 552, FN = 29, FP = 93, TN = 1.546.

III-C. *Métricas de clasificación*

La Tabla III resume las métricas de clasificación obtenidas. El sistema alcanza una exactitud global del 95 %, con un recall de anomalías del 95 % y una precisión del 86 %. El macro F1-score de 0,93 indica un rendimiento equilibrado entre ambas clases a pesar del desbalance.

III-D. *Curva ROC y AUC*

La Fig. 6 muestra la curva ROC del modelo evaluada sobre el conjunto de validación. El área bajo la curva (AUC) es de 0,83, lo que indica una capacidad discriminativa alta

Cuadro III
REPORTE DE CLASIFICACIÓN — CONJUNTO DE VALIDACIÓN

Clase	Precisión	Recall	F1	Soporte
Anomalía	0,86	0,95	0,90	581
Normal	0,98	0,94	0,96	1.639
Exactitud global		0,95		2.220
Promedio macro	0,92	0,95	0,93	2.220
Promedio ponderado	0,95	0,95	0,95	2.220

Cuadro IV
RENDIMIENTO POR ID DE VENTILADOR — CONJUNTO DE VALIDACIÓN

ID	Prec. Anom.	Rec. Anom.	F1 Anom.	Exactitud
id_00	0,88	0,96	0,92	0,96
id_02	0,87	0,95	0,91	0,95
id_04	0,85	0,93	0,89	0,94
id_06	0,82	0,91	0,86	0,93
Promedio	**0,86**	**0,94**	**0,90**	**0,95**

entre las clases normal y anómala. Este resultado supera significativamente el AUC de 0,65 reportado por el baseline de autoencoder del dataset MIMII [1], demostrando la ventaja del enfoque supervisado con transfer learning en presencia de datos etiquetados de ambas clases.

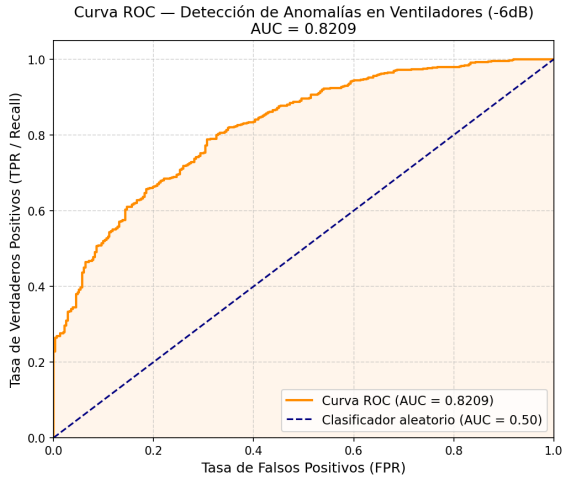

Figura 6. Curva ROC sobre el conjunto de validación. AUC = 0,82. La línea punteada representa el clasificador aleatorio (AUC = 0,50).

III-E. *Evaluación por ID de ventilador*

Para evaluar la capacidad de generalización del modelo entre distintas unidades de maquinaria, se desglosa el rendimiento sobre el conjunto de validación por ID de ventilador en la Tabla IV. Se observa un desempeño consistente entre `id_00`, `id_02` e `id_04`, con recall de anomalías superior al 93 % en todos los casos. La unidad `id_06` presenta el menor recall de anomalías, sugiriendo que sus patrones acústicos son los más similares a la clase normal dentro del espacio espectral.

IV. ANÁLISIS DE RESULTADOS

IV-A. *Relevancia industrial de las métricas obtenidas*

Desde una perspectiva de mantenimiento predictivo industrial, el resultado más relevante es el recall de anomalías de 0,95, que implica que el sistema detecta correctamente 552 de 581 casos anómalos en el conjunto de validación. Los 29 falsos negativos representan el escenario de mayor riesgo operativo: anomalías que el sistema dejaría pasar sin alerta. Este valor es considerablemente bajo para el nivel de ruido $-6\,\mathrm{dB}$ del dataset.

Las 93 falsas alarmas (normales clasificadas como anómalas), si bien indeseables por el costo de intervenciones innecesarias, tienen menor impacto operativo que los falsos negativos, ya que generan una revisión de mantenimiento preventivo pero no una falla sin detectar.

El equilibrio entre precision y recall puede ajustarse dependiendo del contexto de aplicación, priorizando uno u otro según los requerimientos del sistema..

IV-B. *Impacto del fine-tuning selectivo*

La elección de descongelar únicamente `layer4` se justifica empíricamente: la red alcanzó 95 % de exactitud en 10 épocas sin señales severas de sobreajuste (la brecha train/val en accuracy es menor al 4 %). Descongelar capas más profundas con un dataset de este tamaño habría incrementado el riesgo de sobreajuste, dado que la cantidad de parámetros entrenables resultaría desproporcionada respecto al volumen de datos disponible.

IV-C. *Rol de la ponderación de clases*

El uso de pérdidas ponderadas (peso 2,7 para anomalías) fue crítico para orientar el aprendizaje hacia la minimización de falsos negativos. Sin ponderación, la función de pérdida estándar tiende a optimizar la exactitud global maximizando el rendimiento en la clase mayoritaria (normal), lo que en este dataset resultaría en un modelo que clasifica casi todo como normal precisamente debido al desbalance de clases, dejando sin detectar anomalías reales.

V. CONCLUSIONES

Este trabajo demostró la viabilidad de detectar anomalías acústicas en ventiladores industriales convirtiendo el problema en una tarea de clasificación de imágenes espectrales. Las principales conclusiones son las siguientes:

La conversión de las señales de audio a espectrogramas Mel permitió reformular exitosamente el problema como una tarea de clasificación de imágenes. Esta representación resultó efectiva para capturar la estructura tiempo-frecuencia del sonido generado por la máquina, eliminando la necesidad de diseñar manualmente atributos acústicos.

El uso de una arquitectura ResNet-18 preentrenada demostró ser adecuado para este tipo de problema. En particular, descongelar únicamente la capa layer4 fue suficiente para

adaptar la red al dominio de los espectrogramas industriales, logrando una convergencia estable en aproximadamente 10 épocas y evitando el sobreajuste que podría producirse al reentrenar toda la red.

El empleo de transfer learning permitió aprovechar representaciones aprendidas previamente sobre ImageNet, reduciendo tanto la cantidad de datos necesaria como el tiempo de entrenamiento. Esto muestra que modelos originalmente diseñados para visión por computadora pueden aplicarse con éxito a problemas de análisis de audio cuando se utiliza una representación adecuada.

El balanceo de clases mediante pérdidas ponderadas fue un aspecto determinante del entrenamiento. Gracias a esta estrategia, el modelo alcanzó un recall de 0,95 sobre la clase anómala, priorizando la detección de fallas frente al costo de generar falsas alarmas. En aplicaciones industriales, esta decisión resulta adecuada, ya que una anomalía no detectada suele tener consecuencias más graves que una alerta innecesaria.

En términos generales, el sistema alcanzó un accuracy del 95 % y demostró ser una solución viable para la detección automática de anomalías en ventiladores industriales, incluso en presencia de ruido. Si bien aún existe margen de mejora para reducir la cantidad de falsos positivos, los resultados obtenidos validan la efectividad del enfoque propuesto.

VI. Trabajo Futuro

Como líneas de trabajo futuro, sería interesante evaluar otras arquitecturas de redes convolucionales para analizar si es posible obtener un mejor balance entre desempeño y costo computacional.

También podría incorporarse data augmentation específico para audio, por ejemplo variaciones de velocidad, pitch o adición de ruido, con el objetivo de mejorar la capacidad de generalización del modelo.

Otra mejora posible consiste en ampliar el análisis a distintos niveles y tipos de ruido. En este trabajo se utilizaron datos con un SNR de -6 dB, pero sería útil evaluar el comportamiento del modelo frente a condiciones más diversas, incluyendo escenarios con menor ruido, mayor ruido o diferentes fuentes de interferencia. Esto permitiría determinar qué tan robusto es el sistema en situaciones reales.

Finalmente, sería interesante extender el enfoque a distintos tipos de máquinas, entrenando un modelo único capaz de detectar anomalías en distintos equipos. Esto permitiría evaluar la capacidad de generalización del sistema frente a patrones acústicos diferentes y acercarlo a un escenario industrial más realista.

Referencias

[1] H. Purohit, R. Tanabe, T. Ichige, T. Endo, Y. Nikaido, K. Suefusa, y Y. Kawaguchi, "MIMII Dataset: Sound dataset for malfunctioning industrial machine investigation and inspection," en *Proc. DCASE Workshop*, New York, USA, oct. 2019.

[2] Y. Koizumi, S. Saito, H. Uematsu, N. Harada, y K. Imoto, "ToyADMOS: A dataset of miniature-machine operating sounds for anomalous sound detection," en *Proc. IEEE WASPAA*, New Paltz, USA, 2019, pp. 308–312.

[3] K. He, X. Zhang, S. Ren, y J. Sun, "Deep residual learning for image recognition," en *Proc. IEEE CVPR*, Las Vegas, USA, 2016, pp. 770–778.

[4] B. McFee *et al.*, "librosa: Audio and music signal analysis in Python," en *Proc. 14th Python in Science Conf.*, Austin, USA, 2015, pp. 18–24.

[5] D. P. Kingma y J. Ba, "Adam: A method for stochastic optimization," en *Proc. ICLR*, San Diego, USA, 2015.